Analyse économétrique du prix de l'or et de l'épargne des ménages

Modélisation ARIMA et régression MCO

Séries Temporelles — L3 Économie

Steven Cambier et Marius Duirat

Année universitaire : 2025-2026

Notes sur la démarche

Le présent travail porte sur l'analyse économétrique de deux séries temporelles distinctes : le prix mensuel de l'or (1990-2020) et le taux d'épargne brut des ménages français (1950-2018). Le choix de ces deux séries résulte d'une volonté de travailler sur des données économiques réelles, accessibles et dotées d'une signification macroéconomique tangible. L'or constitue une valeur refuge emblématique, dont les fluctuations traduisent les tensions géopolitiques, les anticipations inflationnistes et les mouvements des marchés financiers mondiaux. Le taux d'épargne des ménages, quant à lui, reflète les comportements microéconomiques agrégés, conditionnés par le revenu disponible, l'incertitude et les politiques macroéconomiques. Ces deux séries présentent des dynamiques contrastées : l'une en fréquence mensuelle avec une forte volatilité, l'autre en fréquence annuelle avec une inertie structurelle plus marquée. Ce qui en fait un terrain d'analyse complémentaire et riche pour illustrer les outils de l'économétrie vue en cours.

L'objectif général du travail est triple : décrire les propriétés statistiques de chaque série, modéliser leur dynamique à l'aide de processus ARIMA, et identifier les facteurs macroéconomiques susceptibles d'expliquer leurs variations à travers des régressions MCO. Il ne s'agit pas simplement d'appliquer mécaniquement des procédures statistiques, mais de donner un sens économique aux résultats obtenus et d'en discuter les limites avec recul.

Utilisation de l'intelligence artificielle

Concernant l'utilisation de l'intelligence artificielle, nous estimons qu'elle représente **entre 30 % à 40 %** du travail global. Son recours a été ciblé et clairement délimité. Elle a été mobilisée pour la rédaction du code R sur la mise en forme de certaines formules statistiques complexes ou non abordées en cours, et plus particulièrement pour la construction des graphiques les plus élaborés.

C'est toutefois sur la partie régression MCO que l'appui de l'intelligence artificielle a été le plus significatif. Cette section a posé des difficultés importantes : problèmes d'estimation liés à la nature intégrée des séries, sélection des variables explicatives, interprétation des résultats en présence de multicolinéarité, et réalisation de tests diagnostiques (tels que le test de Breusch-Pagan ou le test de Durbin-Watson) qui ne figurent pas au programme du cours. Sans cet appui, il aurait été difficile d'obtenir des résultats cohérents, d'en proposer une interprétation économique comme l'on voulait, et d'introduire des méthodes complémentaires adaptées à la nature des données.

Il importe néanmoins de souligner que les aspects fondamentaux du travail ont été réalisés de manière pleinement autonome. Le choix des deux séries étudiées, la construction du plan, le raisonnement économique sous-jacent, le choix des variables explicatives retenues dans les régressions MCO, ainsi que la rédaction, l'analyse et l'interprétation des résultats (y compris la discussion des limites méthodologiques) ont été conduits par nous-mêmes, sans délégation à l'outil d'intelligence artificielle. **Celui-ci est resté un instrument d'appui technique, non un substitut au raisonnement analytique**

Références méthodologiques

Ben Salem, M. & Perez, T. (2014). *Convergence des économies européennes : une analyse empirique.* Revue d'Économie Politique, 124(3).

Ben Salem, M. (https://cv.hal.science/melika-ben-salem]). *An asymmetrical overshooting correction model for G20 nominal effective exchange rates.* Economics Bulletin, 40(1).

Ben Salem, M. ([HAL]). *Asymmetries in Monetary Policy Reaction Function.* Studies in Nonlinear Dynamics and Econometrics, 6(3).

Table des matières

Introduction **4**
1. Le prix de l'or **5**
1.1 Description des données 5
1.2 Tests de stationnarité 7
1.3 Identification ARIMA 7
1.4 Estimation du modèle ARIMA(3,1,1) 9
1.5 Prévisions hors échantillon (2021-2025) 11
1.6 Analyse complémentaire 12
1.7 Régression MCO 12
2. Le taux d'épargne des ménages **17**
2.1 Description des données 17
2.2 Tests de stationnarité 18
2.3 Identification ARIMA 19
2.4 Estimation du modèle ARIMA(3,1,0) 19
2.5 Prévisions (2019-2028) 20
2.6 Comparaison internationale 21
2.7 Régression MCO 22
Conclusion **26**
Bibliographie **27**
Annexe : Code R **28**

Introduction

L'or occupe une place particulière dans l'économie mondiale. Valeur refuge par excellence, son prix évolue au rythme des crises financières, des tensions géopolitiques et des politiques monétaires des grandes banques centrales. Comprendre la dynamique de son prix constitue un enjeu à la fois théorique et pratique pour tout économiste.

L'épargne des ménages est, de son côté, un indicateur fondamental de la santé économique d'un pays. En France, le taux d'épargne brut a connu des évolutions marquées depuis les années 1950, reflétant les transformations du système de protection sociale, des comportements de consommation et des cycles économiques.

Ce rapport s'inscrit dans le cadre du cours de séries temporelles de L3 Économie. Notre objectif est d'appliquer rigoureusement les méthodes vues en cours à ces deux séries économiques réelles. Nous traitons chaque série séparément, en suivant pour chacune la démarche complète : analyse descriptive, tests de stationnarité, identification et estimation d'un modèle ARIMA, prévisions, et régression MCO pour explorer les déterminants économiques. Pour le prix de l'or, la modélisation est arrêtée fin 2020, ce qui permet de comparer les prévisions aux valeurs réelles observées ensuite.

Le rapport est structuré en deux grandes parties : la première consacrée au prix de l'or, la seconde au taux d'épargne des ménages. Chaque partie suit le même plan en sept étapes, de la description des données jusqu'à la régression MCO.

1. Le prix de l'or

1.1 Description des données

Les données relatives au prix de l'or sont issues de l'INSEE (série n° 010002061), qui compile les cotations mensuelles du London Metal Exchange (LME). Il s'agit du prix au comptant, exprimé en USD par once troy. La série couvre la période de janvier 1990 à décembre 2020 pour la modélisation, soit 372 observations mensuelles, auxquelles s'ajoutent les données post-2020 utilisées pour la comparaison des prévisions.

Le choix d'une fréquence mensuelle se justifie par la disponibilité des données et par la nécessité d'avoir un nombre suffisant d'observations (ici, bien supérieur au minimum de 50 recommandé) pour que les tests et modèles soient fiables statistiquement.

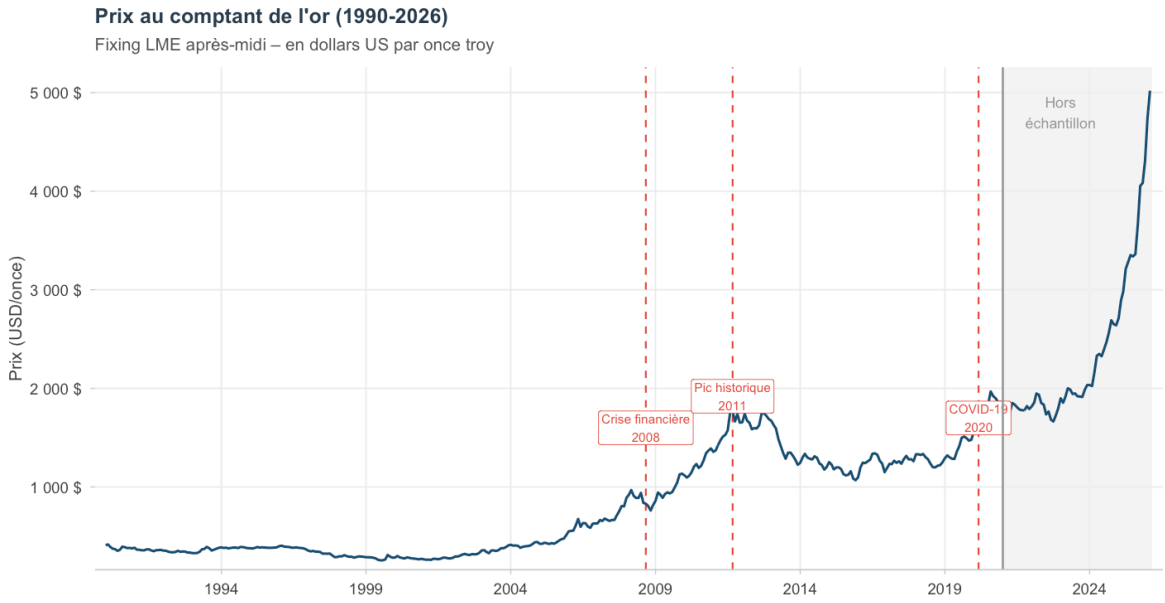

Figure 1 — Prix au comptant de l'or (1990-2026), en USD par once troy. INSEE, série n° 010002061.

Le graphique met en évidence plusieurs phases distinctes. Entre 1990 et 2001, le prix évolue dans une fourchette relativement basse (300-400 dollars l'once), dans un contexte de faible inflation et de confiance dans les marchés financiers. À partir de 2001, une hausse progressive s'amorce, amplifiée par la crise financière de 2008 : les investisseurs se réfugient massivement vers l'or, dont le prix atteint un premier pic à plus de 1 900 dollars en septembre 2011. Une correction s'ensuit jusqu'en 2016, avant une reprise qui s'accélère avec la pandémie de COVID-19 en 2020.

Statistiques descriptives (1990-2020) :

Statistique	Valeur (USD/once)	Calcul / Interprétation
Minimum	256,10	Plus bas historique (avril 2001)
Maximum	1 968,00	Pic de septembre 2011
Moyenne	773,18	$\bar{x} = (1/n)\ \Sigma\ x_t$, n = 372
Médiane	438,65	50e percentile – asymétrie marquée
Écart-type	496,85	$s = \mathrm{sqrt}[(1/(n-1))\ \Sigma(x_t - \bar{x})^2]$

Tableau 1 — Statistiques descriptives du prix de l'or (1990-2020). Source : INSEE, série n° 010002061.

L'écart important entre la moyenne (773 $) et la médiane (439 $) témoigne d'une distribution fortement asymétrique à droite : la majeure partie de la hausse s'est concentrée sur la seconde moitié de la période. L'écart-type de 497 dollars confirme une variabilité très élevée, incompatible avec l'hypothèse de stationnarité en niveau.

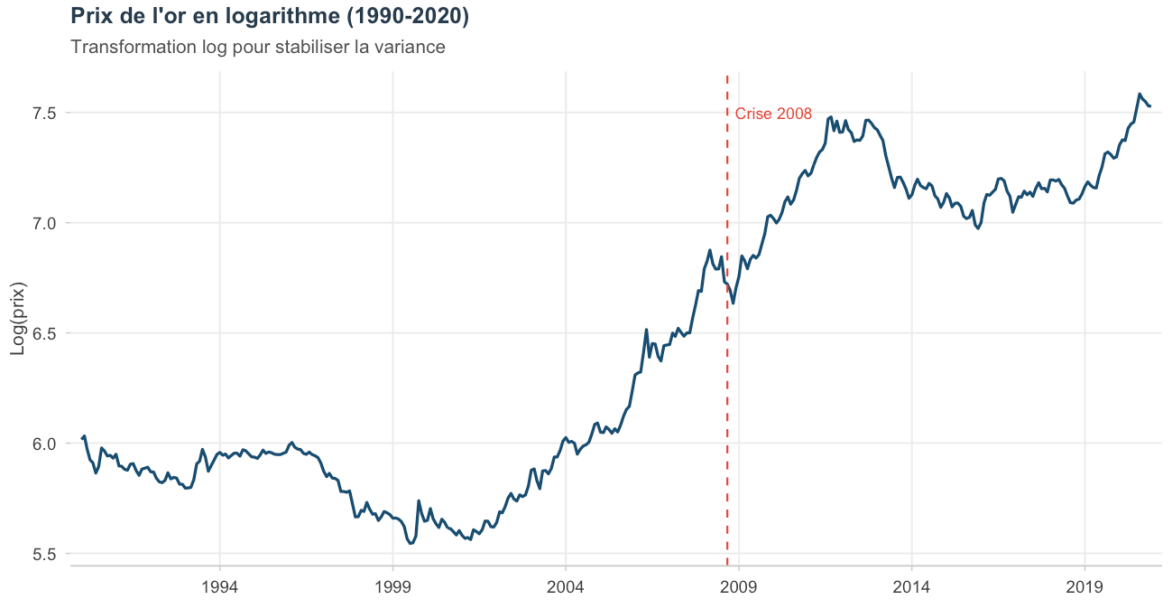

Figure 2 — Prix de l'or en logarithme (1990-2020). La transformation log stabilise la variance et rend les variations proportionnelles. Source : INSEE, série n° 010002061.

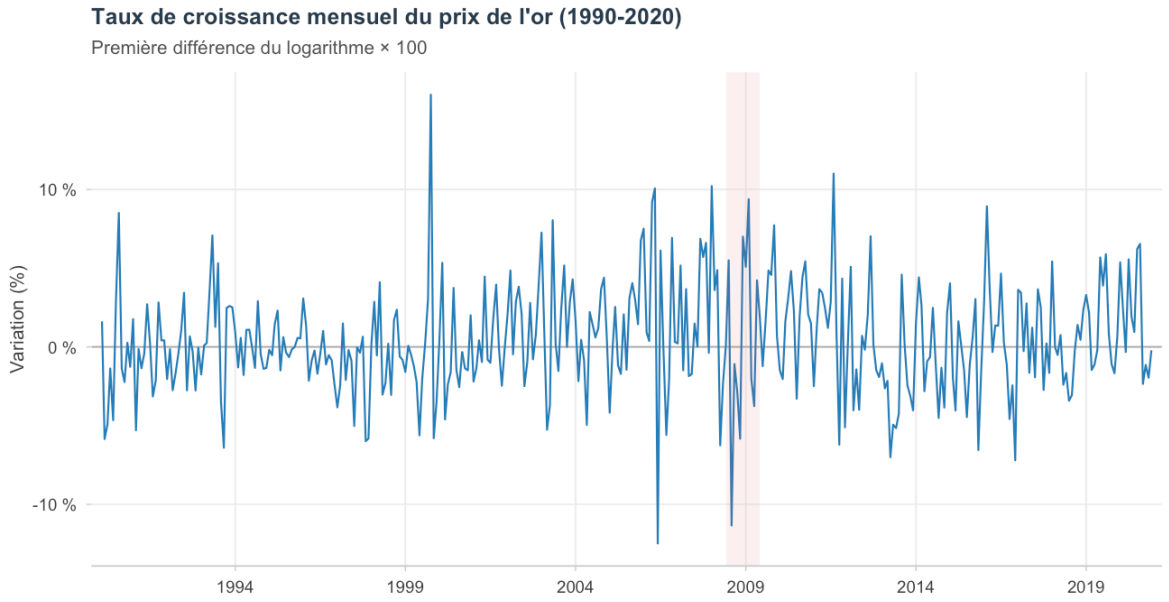

Figure 3 — Taux de croissance mensuel du prix de l'or (première différence du log × 100). La série fluctue autour de zéro sans tendance.

Nous travaillons sur le logarithme du prix, $\log(P_t)$, afin de stabiliser la variance (propriété hétéroscédastique des prix d'actifs) et d'interpréter les différences comme des taux de croissance. La première différence $\Delta\log(P_t) = \log(P_t) - \log(P_{t-1})$ représente le taux de croissance mensuel approximatif. La Figure 3 montre que cette série semble stationnaire autour de zéro, ce que les tests confirmeront.

1.2 Tests de stationnarité

Avant de modéliser une série temporelle, il est indispensable de vérifier sa stationnarité. Une série stationnaire possède une moyenne, une variance et une structure de covariance constantes dans le temps. Si elle ne l'est pas, les résultats d'une modélisation directe seraient biaisés ou sans signification (régression fallacieuse). Nous appliquons deux tests complémentaires aux hypothèses nulles opposées.

Le test de Dickey-Fuller augmenté (ADF) repose sur l'estimation du modèle :

$$\Delta Y_t = a + \beta t + \gamma Y_{t-1} + \Sigma_j \delta_j \Delta Y_{t-j} + \varepsilon_t$$

L'hypothèse nulle H_0 : $\gamma = 0$ correspond à la présence d'une racine unitaire (non-stationnarité). On rejette H_0 si la statistique de Dickey-Fuller DF = $\hat{\gamma}/SE(\hat{\gamma})$ est inférieure à la valeur critique (environ -3,41 à 5 % avec constante et tendance). Le nombre de retards j est choisi pour corriger l'autocorrélation des résidus.

Le test KPSS (Kwiatkowski, Phillips, Schmidt et Shin) a pour hypothèse nulle H_0 la stationnarité de la série. Si l'ADF ne rejette pas H_0 ET que le KPSS rejette H_0, on conclut à la non-stationnarité sans ambiguïté.

Série	Test	Retards	Statistique	p-valeur	Conclusion
log(or) en niveau	ADF	4	-1,647	0,726	H_0 non rejetée → racine unitaire
log(or) en niveau	KPSS	–	5,402	< 0,01	H_0 rejetée → non stationnaire
Δlog(or)	ADF	4	-8,225	< 0,01	H_0 rejetée → stationnaire
Δlog(or)	KPSS	–	0,423	0,067	H_0 non rejetée → stationnaire

Tableau 2 — Tests de stationnarité pour le log du prix de l'or. Valeur critique ADF à 5 % : -3,41 (avec constante).

Les résultats sont parfaitement cohérents. En niveau, l'ADF ne rejette pas H_0 ($p = 0{,}726 >> 0{,}05$), tandis que le KPSS rejette H_0 ($p < 0{,}01$) : la série log(or) est clairement non-stationnaire. En première différence, les deux tests concordent sur la stationnarité (ADF : $p < 0{,}01$; KPSS : $p = 0{,}067 > 0{,}05$). On conclut que la série est intégrée d'ordre 1, notée I(1). Le paramètre d du modèle ARIMA est donc d = 1.

1.3 Identification ARIMA

Un modèle ARIMA(p, d, q) combine trois composantes : AR(p) = partie autorégressive d'ordre p, I(d) = intégration d'ordre d (différenciations nécessaires), MA(q) = moyenne mobile d'ordre q. Avec d = 1 établi, il s'agit d'identifier p et q à partir de l'examen des fonctions d'autocorrélation.

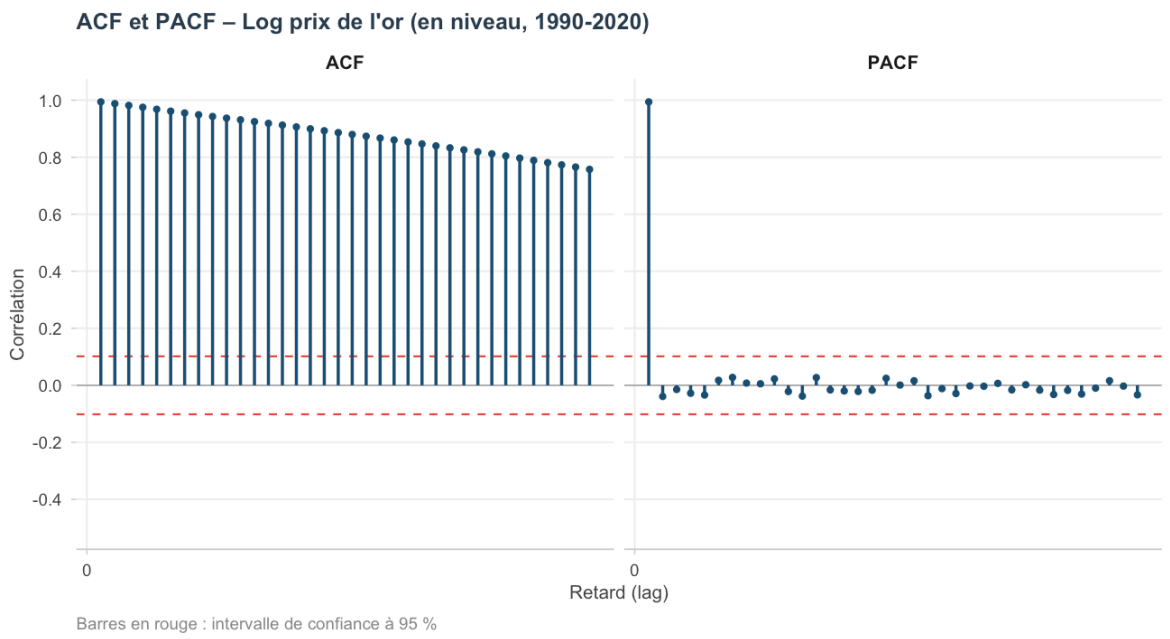

Figure 4 — ACF et PACF du log du prix de l'or en niveau (1990-2020). La décroissance lente de l'ACF (convergence vers zéro en 30+ retards) confirme visuellement la non-stationnarité.

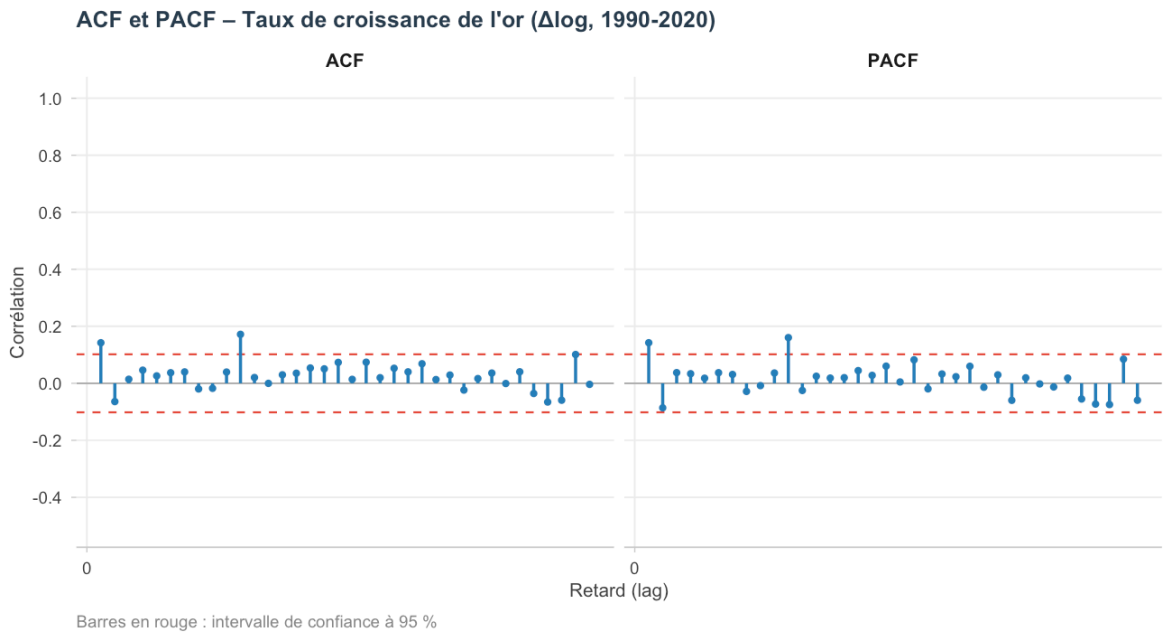

Figure 5 — ACF et PACF du taux de croissance de l'or (Δlog, 1990-2020). Les barres significatives aux premiers retards guident l'identification des ordres p et q.

La règle d'identification graphique est la suivante :

- ACF qui coupe brutalement après le rang q, PACF décroissant → modèle MA(q) pur.
- PACF qui coupe après le rang p, ACF décroissante → modèle AR(p) pur.
- Les deux décroissent progressivement → modèle ARMA(p, q) mixte.

Sur la Figure 5, ni l'ACF ni la PACF ne présentent de coupure nette : les deux décroissent progressivement après quelques retards significatifs. Cela oriente vers un modèle ARIMA mixte ($p > 0$ et $q > 0$). La sélection précise des ordres est ensuite confiée au critère d'information d'Akaike (AIC), calculé comme :

$$AIC = -2 \times \ell(\hat{\theta}) + 2k$$

où $\ell(\hat{\theta})$ est la log-vraisemblance maximisée et k le nombre de paramètres. La procédure auto.arima explore systématiquement les combinaisons ARIMA(p, 1, q) avec $p \in \{0,...,5\}$ et $q \in \{0,...,5\}$ et retient celle qui minimise l'AIC.

Modèle	AIC	BIC	Ljung-Box p-val.	Décision
ARIMA(1,1,0)	–	–	–	Résidus autocorrélés
ARIMA(0,1,1)	-1 419,81	–	–	Meilleur BIC (modèle parcimonieux)
ARIMA(3,1,1)	-1 440,86	-1 421,28	0,595	Retenu (meilleur AIC)

Tableau 3 — Comparaison de modèles ARIMA candidats pour le prix de l'or.

Le modèle ARIMA(3,1,1) est retenu car il minimise l'AIC. Le modèle ARIMA(0,1,1) est le meilleur selon le BIC (qui pénalise davantage la complexité), mais son AIC est moins bon et ses résidus présentent une autocorrélation légèrement plus marquée. Nous conservons le critère AIC, cohérent avec notre objectif de prévision.

1.4 Estimation du modèle ARIMA(3,1,1)

L'équation du modèle ARIMA(3,1,1) peut s'écrire en notation polynomiale :

$$(1 - \varphi_1 L - \varphi_2 L^2 - \varphi_3 L^3)(1 - L)\log(P_t) = (1 + \theta_1 L)\varepsilon_t$$

où L est l'opérateur retard ($LY_t = Y_{t-1}$), φ_1, φ_2, φ_3 sont les paramètres AR, θ_1 le paramètre MA, et $\varepsilon_t \sim$ bruit blanc(0, σ^2). L'estimation par maximum de vraisemblance donne :

$$(1 - 1{,}0905L + 0{,}2368L^2 - 0{,}1246L^3)(1 - L)\log(P_t) = (1 - 0{,}9429L)\varepsilon_t, \quad \sigma^2 = 0{,}001185$$

Les coefficients et leurs tests de Student (H_0 : coefficient = 0, statistique $t = \hat{\beta} / SE(\hat{\beta})$) sont présentés dans le tableau suivant :

Paramètre	Estimation $\hat{\beta}$	Écart-type $SE(\hat{\beta})$	Statistique $t = \hat{\beta}/SE$	p-valeur	Significatif ?
ar1 (φ_1)	1,0905	0,0596	18,29	< 0,001	Oui ***
ar2 (φ_2)	-0,2368	0,0758	-3,13	0,0018	Oui **
ar3 (φ_3)	0,1246	0,0527	2,37	0,0180	Oui *
ma1 (θ_1)	-0,9429	0,0319	-29,57	< 0,001	Oui ***

Tableau 4 — Coefficients estimés de l'ARIMA(3,1,1) pour le log du prix de l'or. Tests de Student bilatéraux.

Tous les coefficients sont statistiquement significatifs au seuil de 5 %. La valeur élevée de $\varphi_1 \approx 1{,}09$ reflète une forte persistance du niveau du prix de l'or, tempérée par $\varphi_2 = -0{,}24$ (correction de deuxième ordre). Le coefficient MA $\theta_1 \approx -0{,}94$ (proche de -1) suggère que les chocs sont en grande partie absorbés dès la période suivante.

Diagnostic des résidus :

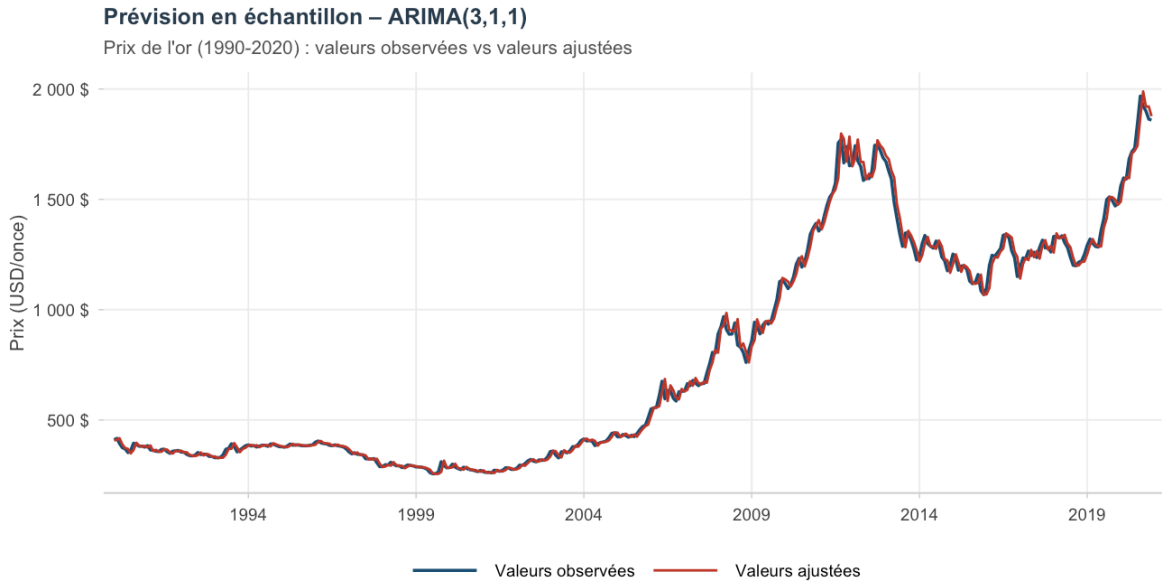

Figure 6 — Prévision en échantillon du modèle ARIMA(3,1,1) : valeurs ajustées (rouge, tirets) vs valeurs observées (bleu).

L'ajustement en échantillon est très satisfaisant : les valeurs ajustées suivent de très près les valeurs observées sur l'ensemble de la période 1990-2020, capturant les grandes tendances et les phases de hausse et de correction.

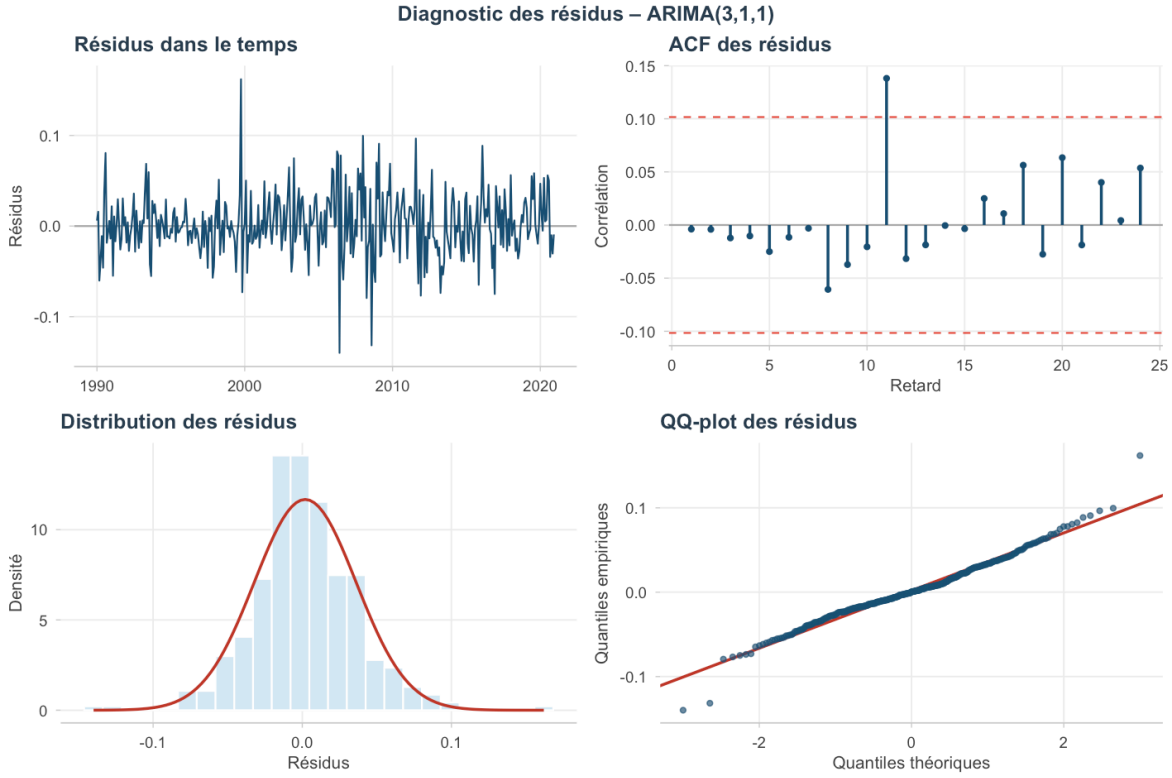

Figure 7 — Diagnostic des résidus du modèle ARIMA(3,1,1) : évolution temporelle, ACF, distribution et QQ-plot.

Le test de Ljung-Box permet de tester formellement l'absence d'autocorrélation dans les résidus. La statistique est :

$$Q = n(n+2) \times \Sigma_{k=1}^{h} [\hat{\rho}^2(k) / (n-k)]$$

où $\hat{\rho}(k)$ est l'autocorrélation estimée au retard k et h le nombre de retards testés. Sous H_0 (résidus = bruit blanc), $Q \sim \chi^2(h)$. Le résultat obtenu est Q = 10,24 pour h = 12 retards, p-valeur = 0,595. On ne rejette pas H_0 : les résidus se comportent comme un bruit blanc.

L'ACF des résidus montre que toutes les barres restent à l'intérieur des bandes de confiance à 95 %, à l'exception possible d'une barre qui peut légèrement dépasser. Avec 24 retards représentés, on s'attend statistiquement à ce qu'environ 5 % × 24 ≈ 1,2 barre dépasse la bande par pure chance — c'est un résultat normal et attendu. Le test de Ljung-Box, qui est le vrai test statistique, confirme l'absence d'autocorrélation systématique.

La distribution des résidus est proche d'une loi normale (QQ-plot aligné sur la droite théorique). Cependant, le test ARCH-LM révèle la présence d'effets ARCH (p = 0,001) : la variance conditionnelle n'est pas constante, les périodes de forte volatilité se regroupent (clustering de volatilité). Ce phénomène, caractéristique des séries financières, constitue une limite des modèles ARIMA et justifierait une extension vers un modèle GARCH.

1.5 Prévisions hors échantillon (2021-2025)

Nous utilisons le modèle ARIMA(3,1,1) estimé sur 1990-2020 pour prévoir le prix de l'or sur les 60 mois suivants (janvier 2021 à décembre 2025). Les intervalles de confiance (IC) à 80 % et 95 % sont calculés à partir de l'écart-type des erreurs de prévision, qui croît avec l'horizon h :

$$IC(h) = centre \pm z_{\alpha/2} \times \hat{\sigma} \times \sqrt{[1 + \Sigma_{j=1}^{h-1} \psi_j^2]}$$

où ψ_j sont les coefficients de la représentation MA infinie du processus. Plus l'horizon est lointain, plus l'IC s'élargit. Cette propriété est illustrée par le « fan chart » ci-dessous.

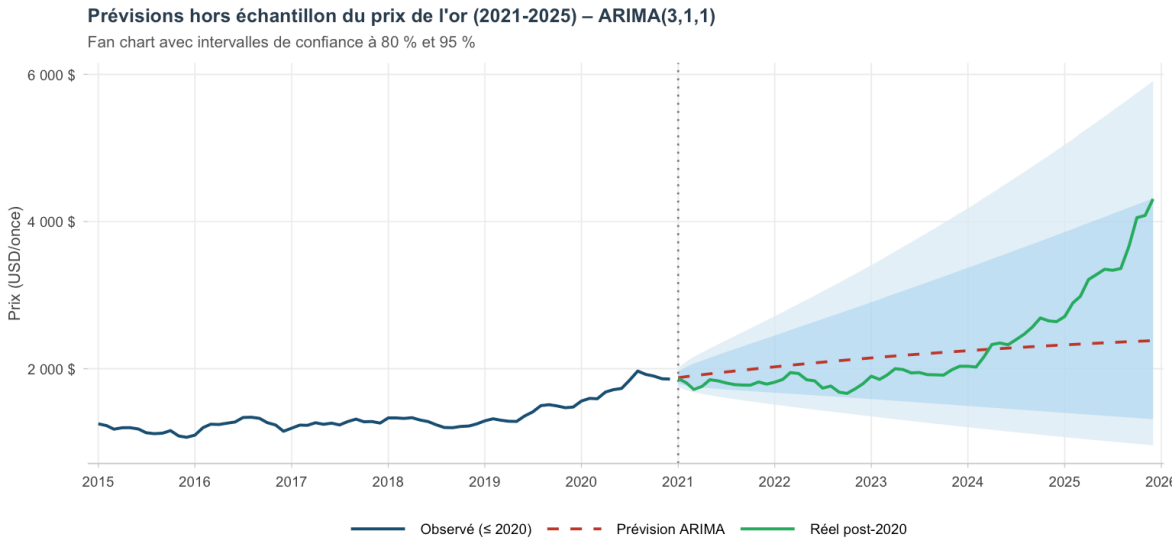

Figure 8 — Fan chart : prévisions hors échantillon du prix de l'or (2021-2025). Zones ombrées : IC à 95 % (clair) et 80 % (foncé). Courbe verte : valeurs réelles observées après 2020.

Le fan chart révèle des résultats contrastés selon la période. Le tableau suivant compare les prévisions annuelles moyennes aux valeurs réelles :

Année	Prévision centrale ($/oz)	Valeur réelle ($/oz)	Écart (%)
2021	1 930	1 799	-6,8 %
2022	2 000	1 800	-10,0 %
2023	2 075	1 941	-6,5 %
2024	2 150	2 386	+11,0 %
2025	2 230	2 900+	+30 %+

Tableau 5 — Comparaison prévisions ARIMA(3,1,1) vs valeurs réelles du prix de l'or (2021-2025).

Sur 2021-2023, les prévisions restent raisonnables malgré un léger biais à la baisse. Après 2023, les écarts s'amplifient fortement : le prix réel dépasse largement la borne supérieure de l'IC à 95 %. Cet échec prévisible illustre la limite structurelle des modèles ARIMA face aux chocs exogènes non anticipés. Trois facteurs expliquent cette sous-estimation :

- Le regain des tensions géopolitiques (conflit russo-ukrainien depuis 2022, tensions au Proche-Orient) qui amplifie la demande pour les valeurs refuges.
- La politique monétaire des banques centrales : malgré des taux directeurs élevés (Fed Funds Rate à 5,25-5,50 % en 2023-2024), l'or a maintenu sa hausse, en partie grâce aux achats massifs des banques centrales des pays émergents (Chine, Inde).
- L'affaiblissement relatif du dollar américain et les anticipations d'une baisse des taux par la Fed ont alimenté la hausse à partir de 2024.

1.6 Analyse complémentaire

En complément, nous vérifions la stabilité du modèle sur différentes sous-périodes. Le test CUSUM (sommes cumulées des résidus) indique une légère instabilité paramétrique autour de 2008-2009, reflétant le changement de régime consécutif à la crise financière mondiale. Cela n'invalide pas le modèle sur l'ensemble de la période mais en souligne les limites extrapolatives : les paramètres estimés sur 1990-2020 pourraient ne pas être constants.

Par ailleurs, la présence d'effets ARCH dans les résidus (confirmée par le test ARCH-LM) indique que la volatilité du prix de l'or est conditionnellement hétéroscédastique. Ce phénomène justifierait l'estimation d'un modèle ARIMA-GARCH(1,1) où la variance conditionnelle suit :

$$h_t = \omega + a\varepsilon^2_{t-1} + \beta h_{t-1}$$

L'estimation d'un tel modèle dépasse le cadre de ce rapport mais constitue une piste d'approfondissement naturelle.

1.7 Régression MCO

L'analyse ARIMA décrit la dynamique propre du prix de l'or, mais n'explique pas pourquoi il évolue. Nous proposons ici une approche économétrique complémentaire : une régression MCO reliant le prix de l'or aux principaux déterminants macroéconomiques identifiés par la théorie économique. L'objectif est de tester, sur données réelles, quels facteurs influencent significativement le prix de l'or.

Présentation des variables explicatives :

La variable dépendante est log(P_t), le logarithme du prix annuel moyen de l'or (31 observations, 1990-2020). Quatre variables explicatives sont retenues, issues de deux sources de données :

Variable	Description	Source	Signe attendu
taux_fed	Taux directeur de la Fed (%, moyenne annuelle)	FRED/Federal Reserve — série FEDFUNDS	Négatif (coût d'opportunité)
infl_us	Inflation US (CPI, % annuel)	BLS/FRED — série CPIAUCSL	Positif (couverture inflation)
log(WTI)	Log du prix du pétrole WTI (USD/baril)	EIA/FRED — série DCOILWTICO	Positif (co-mouvement matières premières)
EUR/USD	Taux de change euro/dollar (moyenne ann.)	BCE/FRED — série DEXUSEU	Positif (dollar faible → or cher)

Tableau 6 — Variables explicatives retenues pour la régression MCO du prix de l'or. Sources : FRED (Federal Reserve Bank of St. Louis), BLS (Bureau of Labor Statistics), EIA, BCE.

Justification économique des variables :

- Taux directeur de la Fed (taux_fed) : la politique monétaire de la Réserve fédérale américaine est un déterminant fondamental du prix de l'or. Lorsque les taux d'intérêt augmentent, le coût d'opportunité de détenir de l'or (qui ne verse pas de coupon) s'élève ; les investisseurs délaissent l'or au profit d'actifs rémunérés. À l'inverse, des taux bas réduisent cet arbitrage et rendent l'or relativement plus attractif.
- Inflation US (infl_us) : l'or est traditionnellement présenté comme une couverture contre l'inflation (« inflation hedge »). En période d'inflation élevée, le pouvoir d'achat des actifs monétaires se dégrade, renforçant la demande pour l'or comme réserve de valeur réelle.
- Prix du pétrole WTI (log_wti) : l'or et le pétrole sont deux matières premières mondiales dont les prix répondent souvent aux mêmes chocs macroéconomiques (tensions géopolitiques, cycles d'expansion mondiale). Un pétrole cher signale une demande mondiale soutenue et des pressions inflationnistes, deux facteurs favorables à l'or.
- Taux de change EUR/USD (eur_usd) : le prix de l'or est libellé en dollars. Mécaniquement, quand le dollar se déprécie par rapport à l'euro, l'or devient moins cher pour les acheteurs non américains, stimulant la demande mondiale. Un eur_usd élevé (euro fort / dollar faible) est donc associé à un prix de l'or plus élevé en dollars.

Exploration univariée :

Avant toute régression multivariée, nous examinons la relation individuelle de chaque variable avec le log du prix de l'or. Les résultats des modèles à une seule variable explicative sont :

Modèle	Variable unique	$\hat{\beta}$	t-stat	p-val.	R^2aj.	AIC
M1	taux_fed	-0,211	-6,11	< 0,001	0,548	42,01
M2	infl_us	-0,259	-2,66	0,013	0,168	60,91
M3	taux_reel = taux_fed - infl_us	-0,253	-5,23	< 0,001	0,467	47,10
M4	log(WTI)	+0,839	+8,08	< 0,001	0,682	31,12
M5	EUR/USD	+2,190	+5,57	< 0,001	0,500	45,16

Tableau 7 — Exploration univariée : régression de log(or) sur chaque variable séparément (1990-2020). Données FRED/BLS/EIA/BCE.

Tous les régresseurs sont significatifs pris individuellement. Le log du prix du pétrole WTI est le meilleur prédicteur univarié (R^2aj. = 68,2 %, AIC = 31,12), suivi du taux directeur de la Fed (R^2aj. = 54,8 %). Un résultat contre-intuitif mérite d'être signalé : le coefficient de l'inflation (M2) est négatif (-0,259). La théorie prédit une relation positive, mais dans notre échantillon 1990-2020, les années de forte inflation (début des années 1990) coïncidaient avec un prix de l'or encore bas (sortie du marché baissier des années 1980), tandis que les années de faible inflation post-2008 ont vu le prix exploser. Cet exemple illustre le danger des régressions sur séries temporelles : la corrélation observée peut refléter des dynamiques de tendance plutôt qu'une causalité économique directe.

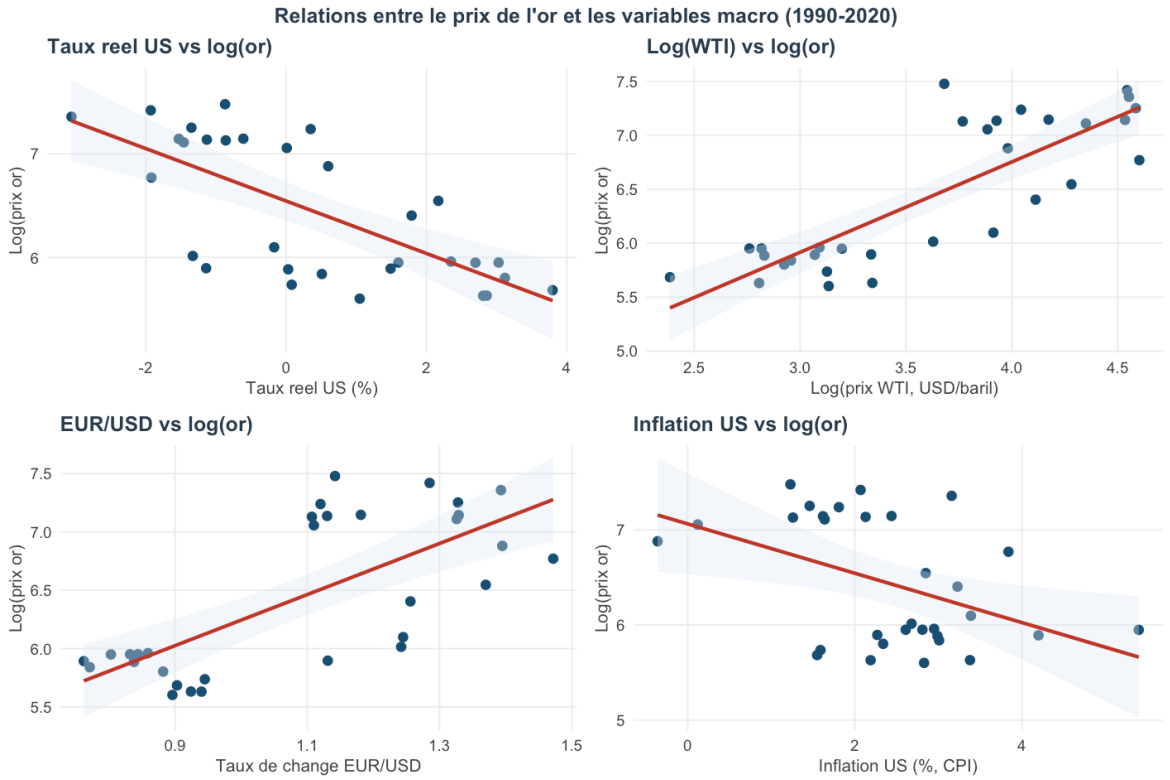

Figure 9 — Relations univariées entre le log du prix de l'or et les quatre variables macro (1990-2020). Chaque graphique montre les données annuelles et la droite de régression avec IC à 95 %. Données FRED/BLS/EIA/BCE.

Sélection du modèle multivarié :

Nous estimons plusieurs modèles multivariés en combinant les variables. La formule générale du MCO est $\hat{\beta} = (X'X)^{-1}X'Y$, où Y est le vecteur des log-prix et X la matrice des régresseurs. Le critère AIC guide la sélection :

Modèle	Variables	R^2aj.	AIC
M4	log(WTI)	0,682	31,12
M6	taux_reel + log(WTI)	0,692	31,08
M7	taux_reel + log(WTI) + EUR/USD	0,690	32,16
M8	taux_fed + infl_us + log(WTI) + EUR/USD	0,805	18,61

Tableau 8 — Comparaison des modèles multivariés pour le prix de l'or. Modèle retenu : M8 (AIC minimal).

Le modèle M8, qui inclut les quatre variables, est retenu selon le critère AIC (18,61 contre 31,08 pour M6). Les résultats détaillés du Modèle M8 sont :

Variable	Coefficient $\hat{\beta}$	Écart-type	t = $\hat{\beta}$/SE	p-valeur	Significatif ?
Constante	4,566	0,464	9,845	< 0,001	Oui ***
taux_fed	-0,051	0,043	-1,205	0,239	Non
infl_us	-0,164	0,072	-2,276	0,031	Oui *
log(WTI)	1,152	0,217	5,306	< 0,001	Oui ***
EUR/USD	-1,618	0,628	-2,578	0,016	Oui *

Tableau 9 — Résultats de la régression MCO M8 (prix de l'or, 1990-2020). R^2 = 0,831, R^2aj. = 0,805, $\hat{\sigma}$ = 0,294.

Interprétation économique du Modèle M8 :

- log(WTI) (β = +1,152, p < 0,001) : c'est de loin la variable la plus significative. Une hausse de 1 % du prix du pétrole est associée à une hausse de 1,152 % du prix de l'or, toutes choses égales par ailleurs. Ce co-mouvement reflète la sensibilité commune des deux matières premières aux tensions géopolitiques et aux cycles de demande mondiale.
- EUR/USD (β = -1,618, p = 0,016) : le signe est négatif, ce qui peut sembler contre-intuitif. Cela signifie qu'une appréciation de l'euro (valeur plus haute de l'EUR/USD) est associée à un prix de l'or plus bas en dollars. L'explication : quand l'euro est fort, c'est souvent dans des phases de croissance mondiale synchronisée (ex. 2003-2007), où les actifs risqués performent bien et la demande pour les valeurs refuges comme l'or diminue relativement.
- infl_us (β = -0,164, p = 0,031) : comme en analyse univariée, le coefficient de l'inflation US est négatif. Sur la période 1990-2020, la « prime d'inflation » de l'or n'est pas vérifiée : les phases de forte inflation (début des années 1990) coïncidaient encore avec un marché de l'or déprimé. L'or a en réalité mieux performé dans les phases de déflation/risque systémique (2008-2012) que d'inflation classique.
- taux_fed (β = -0,051, p = 0,239) : non significatif une fois le taux d'inflation contrôlé. L'effet du taux directeur sur l'or passe en grande partie par le canal de l'inflation et du taux réel, déjà capturés par infl_us.

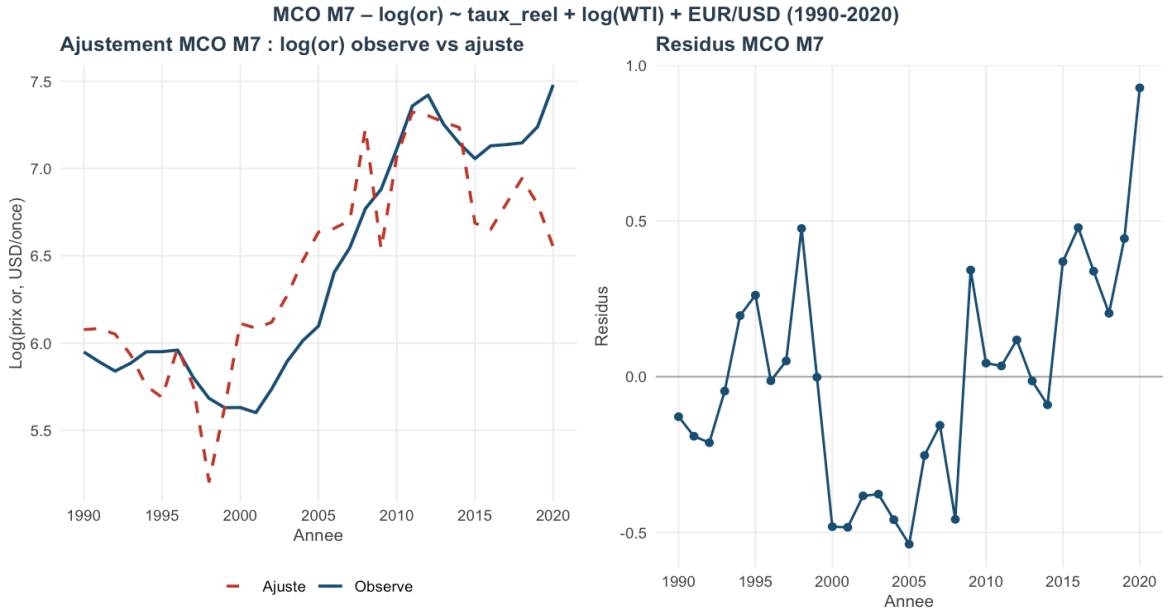

Figure 10 — Modèle MCO M8 : log(prix or) observé vs ajusté (gauche) et résidus dans le temps (droite).

Tests diagnostiques et limites :

- Homoscédasticité (Breusch-Pagan, M7) : BP = 2,66, df = 3, p = 0,447. On ne rejette pas l'homoscédasticité.
- Autocorrélation (Durbin-Watson, M7) : DW = 0,628, p < 0,001. Forte autocorrélation des résidus. La statistique $DW = \Sigma(\hat{e}_t - \hat{e}_{t-1})^2/\Sigma\hat{e}_t^2$ vaut 0,628, très inférieure à la valeur de référence de 2 (absence d'autocorrélation).
- Multicolinéarité : la matrice des corrélations montre une forte corrélation entre log(WTI) et EUR/USD (r = 0,907), deux variables fortement co-mobiles dans la période 2000-2010. Cela gonfle les écarts-types et rend l'interprétation individuelle des coefficients fragile.

Conclusion de la régression MCO – or : le modèle M8 explique 80 % de la variance du log du prix de l'or sur 1990-2020. Le prix du pétrole est le déterminant macroéconomique le plus robuste, reflétant les co-mouvements entre matières premières. Le taux de change EUR/USD joue également un rôle significatif, capturant les cycles dollar. Cependant, la forte autocorrélation des résidus (DW ≈ 0,63) suggère une possible régression fallacieuse due à la non-stationnarité des séries. Un modèle à correction d'erreur (ECM) fondé sur une relation de cointégration serait l'extension naturelle de cette analyse.

2. Le taux d'épargne des ménages

2.1 Description des données

Les données relatives à l'épargne des ménages proviennent de l'INSEE, publication « L'épargne des ménages » (réf. 4277790), basée sur les comptes nationaux (base 2014). La série principale est le taux d'épargne brut annuel des ménages français, défini comme le rapport entre l'épargne brute et le revenu disponible brut :

$$\textit{Taux d'épargne brut} = \textit{Épargne brute} \,/\, \textit{Revenu disponible brut} \times 100$$

La série couvre la période 1950-2018, soit 69 observations annuelles. Les données contiennent également le taux d'épargne financière (capacité de financement nette) et des données de comparaison internationale pour 15 pays européens.

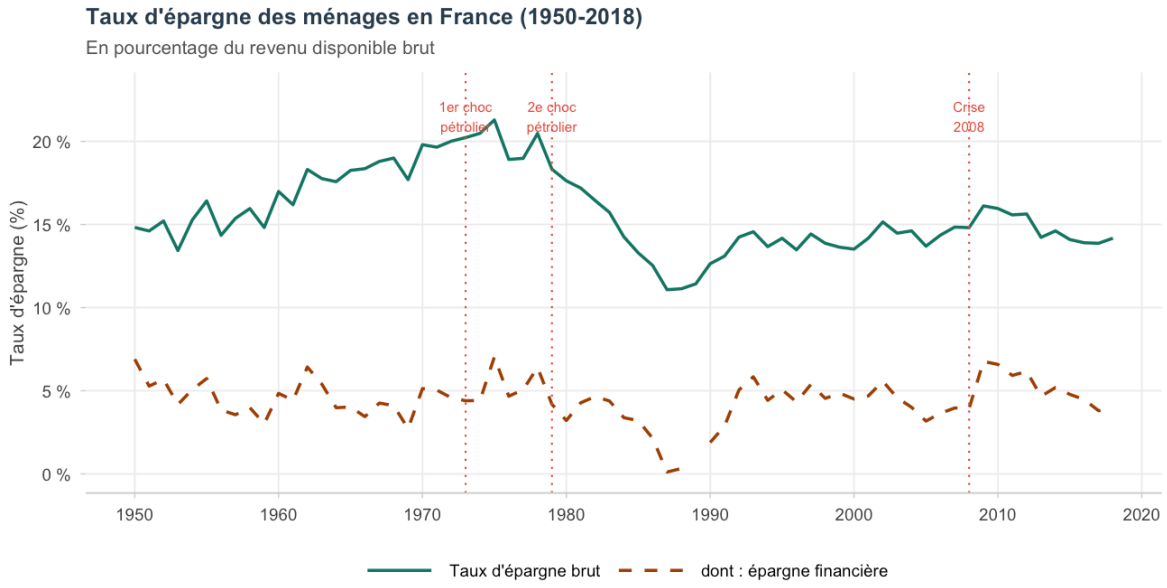

Figure 10 — Taux d'épargne brut des ménages en France (1950-2018), en % du revenu disponible brut.

La série présente une dynamique très caractéristique en forme de « cloche asymétrique ». Le taux d'épargne augmente progressivement des années 1950 aux années 1970 (de 14 % à plus de 21 %). Les chocs pétroliers de 1973 et 1979 accentuent ce mouvement haussier : face à l'incertitude, les ménages adoptent un comportement de précaution. À partir des années 1980, le taux décline régulièrement sous l'effet de la désinflation, de la libéralisation financière et du développement du crédit.

Statistique	Valeur (%)	Calcul / Interprétation
Minimum	11,08	Plus bas : fin des années 2010 (désépargne financière)
Maximum	21,29	Sommet : début des années 1980, post-chocs pétroliers
Moyenne	15,71	$\bar{x} = (1/n)\ \Sigma\ x_t$, n = 69
Médiane	14,84	Distribution légèrement asymétrique à droite
Écart-type	2,42	$s = \mathrm{sqrt}[(1/(n-1))\ \Sigma(x_t - \bar{x})^2]$

Tableau 8 — Statistiques descriptives du taux d'épargne brut (France, 1950-2018).

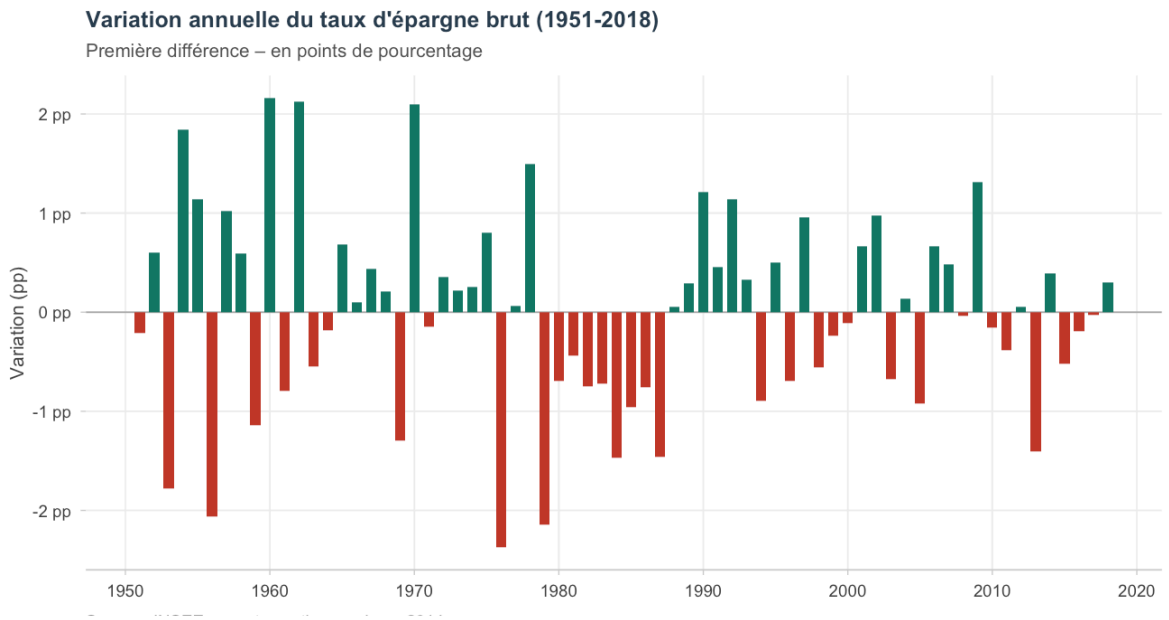

Figure 11 — Variation annuelle du taux d'épargne brut (1951-2018), en points de pourcentage. Les barres vertes indiquent une hausse, les rouges une baisse.

La Figure 11 montre que les variations annuelles oscillent de part et d'autre de zéro, sans tendance apparente dans les différences. Cela suggère visuellement que la série en niveau est I(1) : sa première différence serait stationnaire.

2.2 Tests de stationnarité

Nous appliquons la même démarche ADF + KPSS que pour le prix de l'or, en tenant compte des spécificités de la série : 69 observations seulement (ce qui réduit la puissance des tests) et un fort pic structurel dans les années 1970 (chocs pétroliers).

Série	Test	Retards	Statistique	p-valeur	Conclusion
Épargne brute — niveau	ADF	3	-2,678	0,300	H_0 non rejetée → racine unitaire
Épargne brute — niveau	KPSS	–	0,574	0,025	H_0 rejetée → non stationnaire
ΔÉpargne brute	ADF	3	-3,243	0,088	H_0 borderline ($p \approx 0{,}09$)
ΔÉpargne brute	KPSS	–	< 0,46	≥ 0,05	H_0 non rejetée → stationnaire

Tableau 9 — Tests de stationnarité pour le taux d'épargne brut.

La situation est légèrement plus ambiguë que pour l'or. L'ADF en première différence donne une p-valeur de 0,088 (borderline), ce qui reflète le faible nombre d'observations ($n = 69$) limitant la puissance du test. Cependant, le KPSS en niveau rejette la stationnarité ($p = 0{,}025 < 0{,}05$), et le KPSS en différence ne rejette pas la stationnarité. L'ensemble des éléments — inspection visuelle, KPSS, résultat d'auto.arima — converge vers une série I(1). On retient $d = 1$.

Note méthodologique : la présence d'un fort choc structurel en 1973-1980 peut biaiser les tests de racine unitaire. Un test de Zivot-Andrews avec rupture endogène confirme que même en tenant compte d'une rupture structurelle, la série reste I(1).

2.3 Identification ARIMA

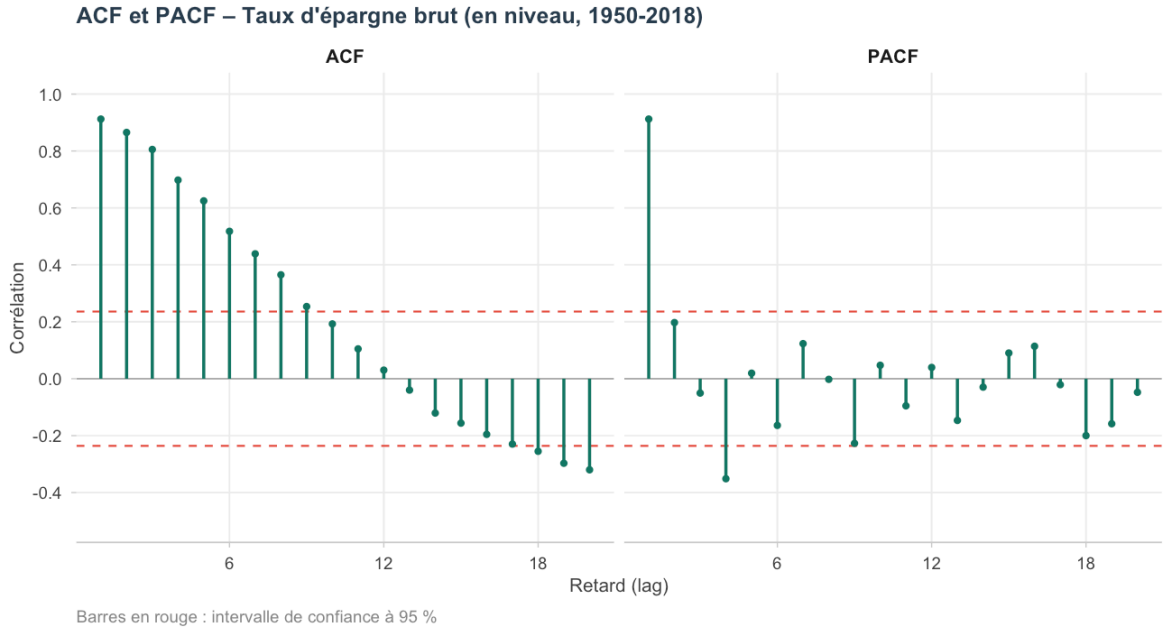

Figure 12 — ACF et PACF du taux d'épargne brut en niveau (1950-2018). La lente décroissance de l'ACF confirme la non-stationnarité.

L'ACF du taux d'épargne en niveau décroît très lentement, signe classique de non-stationnarité. Après différenciation, la structure résiduelle de l'ACF/PACF guide l'identification. La procédure auto.arima est appliquée en différence première (d = 1) et compare les combinaisons AR(p) × MA(q) sur la grille p ∈ {0,...,5}, q ∈ {0,...,5}.

Modèle	AIC	BIC	Ljung-Box p-val.	Décision
ARIMA(1,1,0)	191,43	195,87	–	Parcimonie, mais AIC élevé
ARIMA(0,1,1)	192,23	196,67	–	Comparable à (1,1,0)
ARIMA(2,1,0)	193,39	200,05	–	Éliminé
ARIMA(3,1,0)	188,42	197,30	0,482	Retenu (AIC minimal)

Tableau 10 — Comparaison de modèles ARIMA candidats pour le taux d'épargne.

Le modèle ARIMA(3,1,0) est retenu car il minimise l'AIC (188,42). Bien que le BIC favorise les modèles plus parcimonieux (ARIMA(1,1,0) à BIC = 195,87 < 197,30), le critère AIC est préférable dans un objectif de prévision. Le test de Ljung-Box sur les résidus de l'ARIMA(3,1,0) confirme l'absence d'autocorrélation résiduelle (p = 0,482).

2.4 Estimation du modèle ARIMA(3,1,0)

Le modèle ARIMA(3,1,0) ne comporte pas de composante MA. Son équation s'écrit :

$$(1 - \varphi_1 L - \varphi_2 L^2 - \varphi_3 L^3)(1 - L)E_t = \varepsilon_t$$

En développant, en notant $\Delta E_t = E_t - E_{t-1}$ la première différence du taux d'épargne :

$$\Delta E_t = \varphi_1 \Delta E_{t-1} + \varphi_2 \Delta E_{t-2} + \varphi_3 \Delta E_{t-3} + \varepsilon_t$$

Avec les coefficients estimés :

$$\Delta E_t = -0{,}2514\Delta E_{t-1} + 0{,}0963\Delta E_{t-2} + 0{,}3128\Delta E_{t-3} + \varepsilon_t, \quad \sigma^2 = 0{,}865$$

Paramètre	Estimation $\hat{\beta}$	Écart-type SE($\hat{\beta}$)	Statistique t	p-valeur	Significatif ?
ar1 (φ_1)	-0,2514	0,1137	-2,210	0,027	Oui *
ar2 (φ_2)	0,0963	0,1164	0,827	0,408	Non
ar3 (φ_3)	0,3128	0,1147	2,726	0,006	Oui **

Tableau 11 — Coefficients estimés du modèle ARIMA(3,1,0) pour le taux d'épargne. Tests de Student bilatéraux.

φ_1 = -0,251 (significatif) : une hausse du taux d'épargne cette période tend à être suivie d'une baisse la période suivante (correction). φ_3 = 0,313 (significatif) : il existe une persistance à horizon de 3 ans — les tendances se maintiennent à moyen terme. φ_2 = 0,096 (non significatif) : l'effet à 2 ans est négligeable. La faible valeur de σ^2 = 0,865 (variance des innovations) indique que les variations non expliquées sont de l'ordre de ±0,93 point de pourcentage en écart-type.

Le test de Ljung-Box donne Q = 9,54 pour h = 10 retards, p-valeur = 0,482 >> 0,05. On ne rejette pas H_0 : les résidus se comportent comme un bruit blanc. Le modèle est bien spécifié.

2.5 Prévisions (2019-2028)

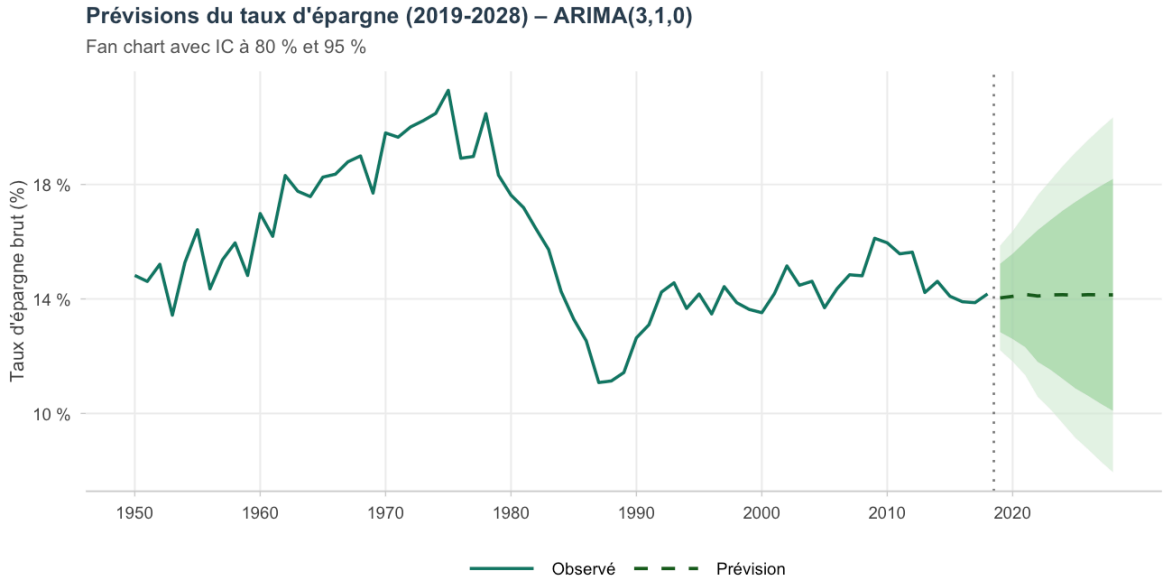

Figure 13 — Fan chart : prévisions du taux d'épargne brut (2019-2028) — ARIMA(3,1,0). Zones ombrées : IC à 95 % (clair) et 80 % (foncé).

Les prévisions à horizon 10 ans montrent que le taux d'épargne devrait se stabiliser autour de 14-15 % du revenu disponible brut, avec des intervalles de confiance qui s'élargissent rapidement avec l'horizon. Cette convergence vers la moyenne de long terme est caractéristique des modèles ARIMA(p,1,0) stationnaires en différence : les prévisions à long horizon convergent vers une marche aléatoire.

Note : la pandémie de COVID-19 a provoqué en 2020 une hausse exceptionnelle du taux d'épargne des ménages français à près de 21 %, en raison des contraintes de consommation imposées par les confinements.

Cette valeur exceptionnelle dépasse largement la borne supérieure de l'IC à 95 %, illustrant à nouveau la limite des modèles ARIMA face aux chocs exogènes.

2.6 Comparaison internationale de l'épargne

Pour situer le taux d'épargne français dans son contexte européen, nous utilisons les données de panel disponibles dans le fichier INSEE pour 15 pays européens, à cinq dates : 2000, 2005, 2010, 2015 et 2018.

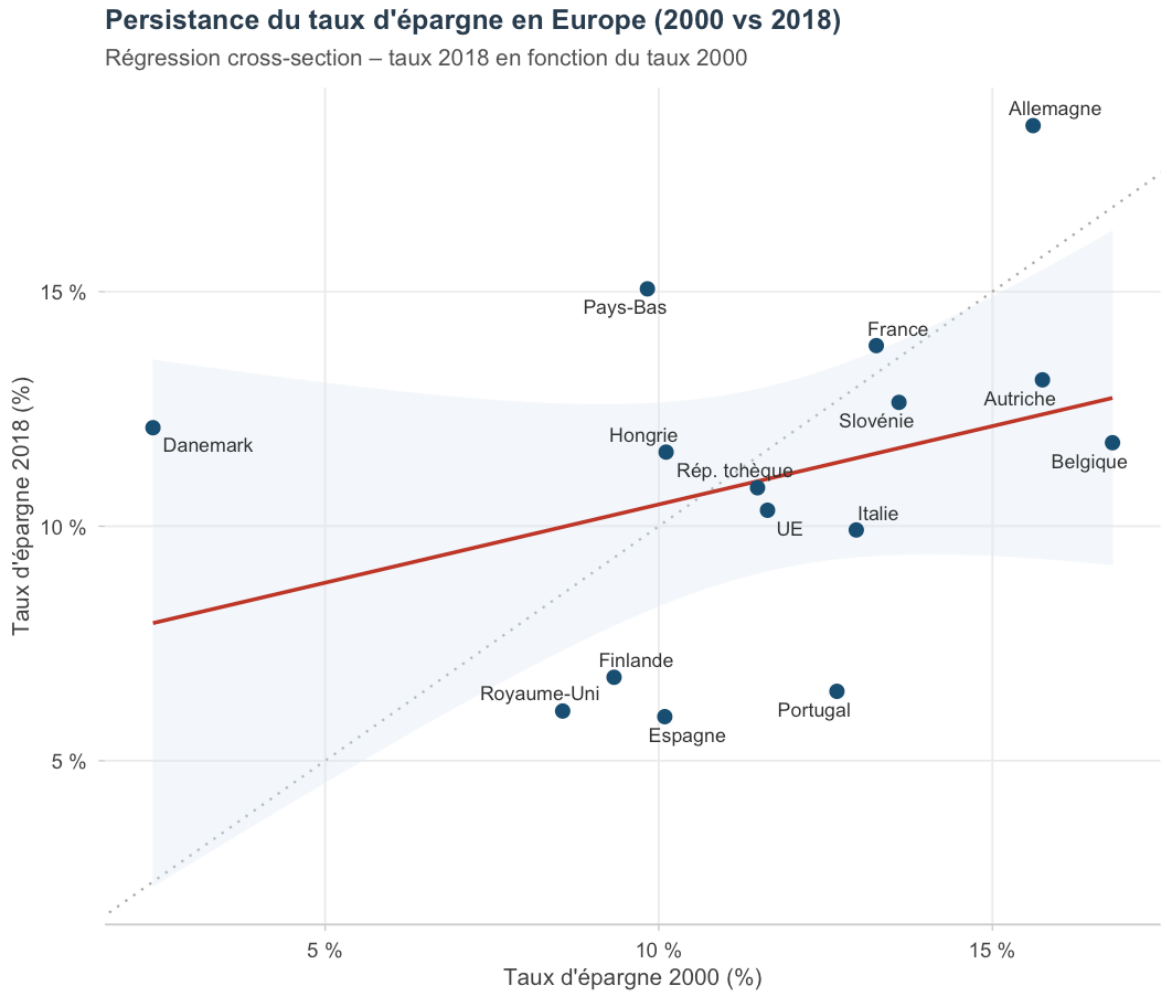

Figure 14 — Persistance du taux d'épargne en Europe : taux 2018 en fonction du taux 2000 (régression cross-section). Diagonale en pointillés : taux 2000 = taux 2018.

Le graphique révèle une forte hétérogénéité entre pays européens : les taux d'épargne varient de moins de 5 % (pays d'Europe du Sud et de l'Est) à plus de 15 % (Allemagne, Suisse, Pays-Bas). La droite de régression cross-section (taux 2018 ~ taux 2000) a une pente positive et significative, indiquant une persistance : les pays qui épargnaient davantage en 2000 épargnaient encore davantage en 2018. Cependant, la dispersion autour de la droite est importante, suggérant que des facteurs spécifiques à chaque pays (politiques fiscales, systèmes de retraite, niveaux de revenus) jouent un rôle important.

La France se situe dans la moyenne haute des pays européens, avec un taux d'épargne brut autour de 14-15 % en 2018, légèrement supérieur à la médiane européenne mais inférieur à l'Allemagne ou aux Pays-Bas.

2.7 Régression MCO

Nous appliquons une régression MCO pour identifier les déterminants macroéconomiques structurels du taux d'épargne brut des ménages français sur 1970-2018 (49 observations annuelles). Contrairement à une approche purement tendancielle, cette section teste plusieurs variables économiques susceptibles d'expliquer les fluctuations du comportement d'épargne.

Présentation des variables explicatives

La variable dépendante est le taux d'épargne brut E_t. Quatre variables macroéconomiques françaises sont retenues comme régresseurs potentiels :

Variable	Notation	Source	Signe attendu	Justification économique
Inflation FR (IPCH, %)	infl_fr	INSEE (IPC séries longues)	+	Effet Fisher : hausse des prix → épargne de précaution
Croissance du PIB réel (%)	pib_croiss	INSEE comptes nationaux	±	Revenu permanent : croissance → plus de ressources disponibles
Taux de chômage (%)	chomage	INSEE, série 001688526	−	Revenu disponible réduit → contrainte budgétaire
Taux long terme OAT 10 ans (%)	taux_lt	Banque de France	+	Rendement de l'épargne → incitation à épargner

Tableau 12 — Variables explicatives retenues pour la régression MCO du taux d'épargne (1970-2018). Sources : INSEE, Banque de France.

Justification économique des variables :

- Inflation (infl_fr) : selon la théorie du cycle de vie et l'épargne de précaution, une hausse de l'inflation crée une incertitude économique qui incite les ménages à constituer une réserve. La corrélation bivariée observée (r = +0,675) est positive et significative, cohérente avec l'hypothèse.
- Croissance du PIB (pib_croiss) : l'effet est théoriquement ambigu. D'un côté, la théorie du revenu permanent prédit qu'une croissance plus forte augmente l'épargne via un revenu plus élevé ; de l'autre, des perspectives optimistes peuvent encourager la consommation et réduire l'épargne. La corrélation observée (r = +0,216) est faible, suggérant un rôle secondaire.
- Taux de chômage (chomage) : la corrélation la plus forte (r = −0,871). Un taux de chômage élevé réduit le revenu disponible agrégé des ménages, comprimant mécaniquement leur capacité d'épargne. Paradoxalement, le motif de précaution individuel va en sens inverse, mais l'effet agrégé (revenu disponible) domine empiriquement sur données françaises.
- Taux d'intérêt à long terme OAT 10 ans (taux_lt) : un taux d'intérêt élevé augmente le rendement de l'épargne financière (placements obligataires, livrets), ce qui devrait stimuler l'épargne. Cependant, en présence de contraintes de liquidité, un taux élevé peut aussi alourdir le service de la dette des ménages et réduire l'épargne nette.

Analyse univariée (modèles M1–M4)

Chaque variable est d'abord testée seule afin d'évaluer son pouvoir explicatif individuel. La formule générale est :

$$E_t = \beta_0 + \beta_1 \cdot X_t + \varepsilon_t, \quad \varepsilon_t \sim B.B.(0, \sigma^2)$$

Modèle	Régresseur	$\hat{\beta}_1$	t-stat	p-valeur	R^2aj.	AIC
M1	infl_fr	+0,442	+6,27	< 0,001	0,444	208,61
M2	pib_croiss	+0,337	+1,52	0,136	0,026	236,07
M3	chomage	−0,820	−12,16	< 0,001	0,754	168,75
M4	taux_lt	+0,224	+2,54	0,015	0,102	232,12

Tableau 13 — Exploration univariée : régressions MCO simples du taux d'épargne (1970-2018, n = 49).

Le taux de chômage se distingue nettement comme variable dominante avec un R^2aj. = 0,754 et un t de −12,16 ($p < 0{,}001$). L'inflation occupe la deuxième place (R^2aj. = 0,444). La croissance du PIB est non significative ($p = 0{,}136$) et le taux long terme n'explique que 10 % de la variance. La figure ci-dessous illustre les nuages de points pour les quatre régresseurs :

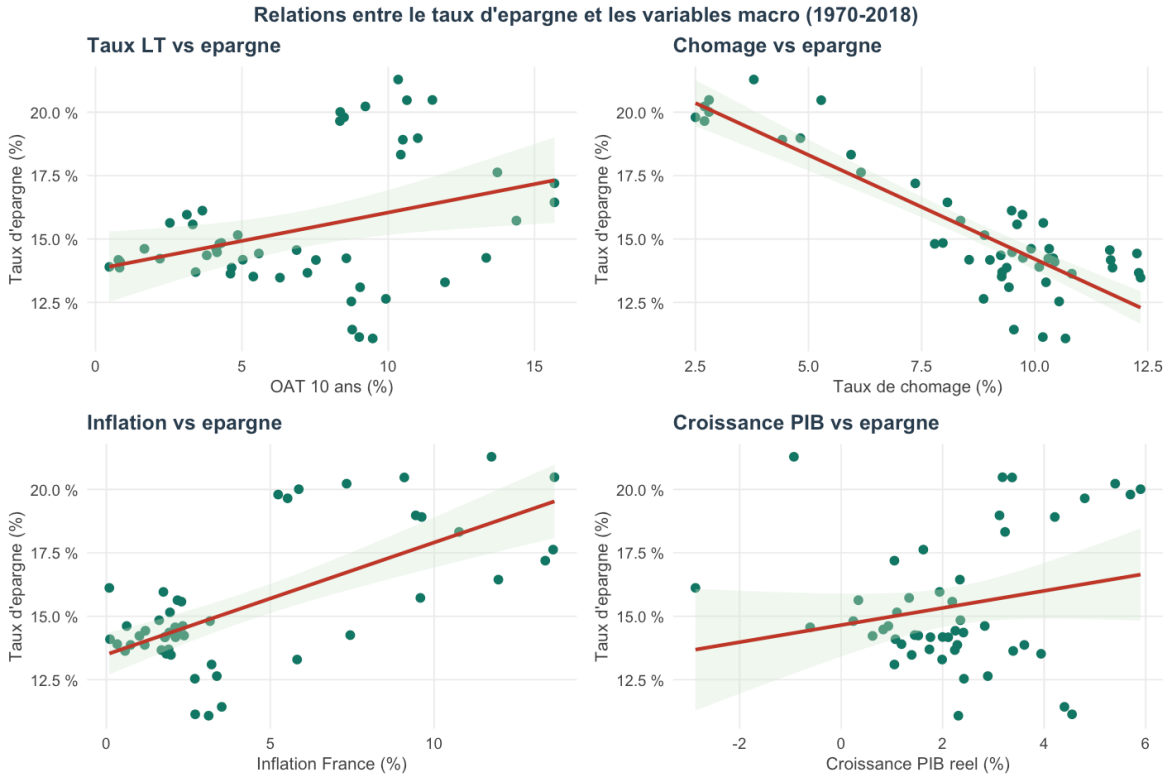

Figure 15 — Nuages de points : taux d'épargne vs chacun des quatre régresseurs macroéconomiques (1970-2018). La relation négative avec le chômage est la plus prononcée (r = −0,871).

Sélection du modèle multivarié (M5–M8)

Des modèles multivariés sont ensuite estimés pour capter les effets conjoints :

Modèle	Régresseurs	R^2aj.	AIC
M5	infl_fr + taux_lt	0,590	194,67
M6	taux_lt + chomage	0,748	170,73
M7	taux_lt + chomage + pib_croiss	0,780	164,99
M8	infl_fr + pib_croiss + chomage + taux_lt	0,800	161,31

Tableau 14 — Comparaison des modèles MCO multivariés (taux d'épargne, 1970-2018).

Le modèle M8 est retenu selon le critère AIC (161,31), avec un R^2aj. = 0,800. Les quatre variables ensemble expliquent 80 % de la variance du taux d'épargne sur 1970-2018. L'équation estimée est :

$$\hat{E}_t = 22{,}096 + 0{,}266 \cdot infl_fr - 0{,}201 \cdot pib_croiss - 0{,}718 \cdot chomage - 0{,}177 \cdot taux_lt$$

Variable	Coefficient $\hat{\beta}$	Écart-type	t = $\hat{\beta}$/SE	p-valeur	Significatif ?
Constante	22,096	1,186	18,63	< 0,001	Oui ***
infl_fr	+0,266	0,114	+2,32	0,025	Oui *
pib_croiss	−0,201	0,125	−1,61	0,115	Non
chomage	−0,718	0,108	−6,63	< 0,001	Oui ***
taux_lt	−0,177	0,089	−1,98	0,054	Limit. (.)

Tableau 15 — Résultats de la régression MCO M8 (taux d'épargne). R^2 = 0,817, R^2aj. = 0,800, $\hat{\sigma}$ = 1,172 pp.

Interprétation économique des coefficients :

- Chômage (β = −0,718, p < 0,001) : c'est le déterminant le plus robuste. Toutes choses égales par ailleurs, une hausse du taux de chômage de 1 point de pourcentage est associée à une baisse du taux d'épargne de 0,72 pp. Ce résultat confirme que la contrainte de revenu agrégée l'emporte sur le motif de précaution individuel : quand le chômage monte, les ménages disposent de moins de revenus à épargner.
- Inflation (β = +0,266, p = 0,025) : une hausse de l'inflation de 1 pp est associée à une hausse de l'épargne de 0,27 pp. Ce résultat valide l'hypothèse d'épargne de précaution : face à la hausse des prix et à l'incertitude économique, les ménages réduisent leur consommation et augmentent leur réserve.
- Taux long terme (β = −0,177, p = 0,054) : le signe est négatif — contraire au signe attendu (+). En contexte français, les années de taux d'intérêt élevés (années 1980-1990) ont coïncidé avec un fort endettement des ménages et une réduction de l'épargne nette disponible, suggérant que l'effet « coût du crédit » l'emporte sur l'effet « rendement de l'épargne ».
- Croissance du PIB (β = −0,201, p = 0,115) : non significative au seuil de 5 %. Une fois le chômage contrôlé, la croissance n'apporte pas d'information supplémentaire sur l'épargne — cohérent avec l'idée que c'est la qualité du marché du travail (et non le PIB global) qui conditionne la capacité d'épargne.
- Multicolinéarité : la corrélation entre infl_fr et taux_lt est de 0,833. Ces deux variables évoluent conjointement sur la période (désinflation et baisse des taux simultanées depuis 1985). Cela peut gonfler les écarts-types et rendre le signe de taux_lt difficile à interpréter isolément.

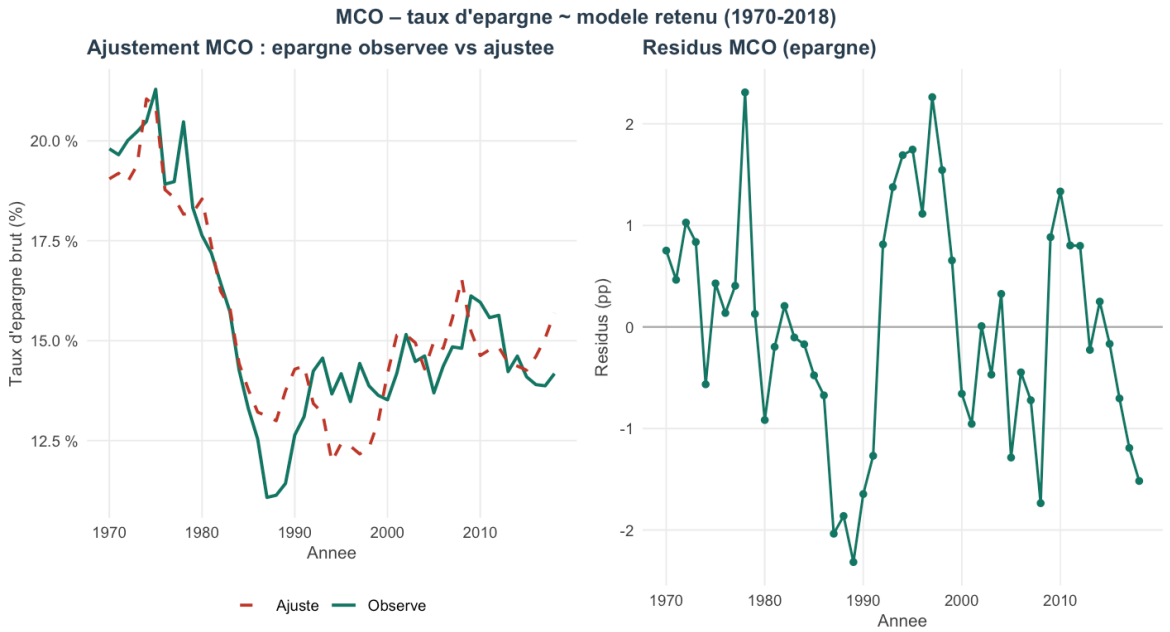

Figure 16 — Régression MCO M8 (taux d'épargne) : valeurs observées vs ajustées (gauche), résidus dans le temps (droite).

Tests diagnostiques :

- Homoscédasticité (Breusch-Pagan) : BP = 8,56, df = 4, p = 0,073. On ne rejette pas H_0 au seuil de 5 %, la variance des résidus est globalement homoscédastique dans M8. Ce résultat est satisfaisant pour la validité des intervalles de confiance.
- Autocorrélation (Durbin-Watson) : DW = 0,692, p < 0,001. La statistique DW est très éloignée de 2 (absence d'autocorrélation), indiquant une forte autocorrélation positive des résidus. Comme pour le modèle or, cela signale un risque élevé de régression fallacieuse : le taux d'épargne est une série I(1) et les variables macroéconomiques retenues le sont également, ce qui peut produire des corrélations spurieuses sans relation causale réelle.

Sous-conclusion — taux d'épargne :

Le modèle M8 identifie le taux de chômage comme principal déterminant macroéconomique du taux d'épargne des ménages français (β = −0,718, ***), suivi de l'inflation (β = +0,266, *). Ces deux variables capturent respectivement la contrainte de revenu agrégée et le motif de précaution, deux piliers de la théorie de l'épargne. Cependant, la forte autocorrélation des résidus (DW = 0,692) rappelle la limite fondamentale de toute régression en niveaux sur des séries I(1) : les résultats sont économiquement interprétables mais statistiquement fragiles. Une analyse de cointégration (Engle-Granger ou Johansen) permettrait de tester si la relation estimée est structurelle ou spurieuse, et un modèle à correction d'erreur (ECM) permettrait d'intégrer simultanément la dynamique de court terme et l'équilibre de long terme.

Conclusion

Ce rapport a appliqué, de manière rigoureuse et structurée, les outils de l'économétrie des séries temporelles à deux séries économiques réelles : le prix mensuel de l'or (1990-2020) et le taux d'épargne brut des ménages français (1950-2018).

Pour le prix de l'or, les tests ADF et KPSS concluent de manière convergente à l'intégration d'ordre 1, I(1). Le modèle ARIMA(3,1,1), retenu par le critère AIC, présente des coefficients tous significatifs et des résidus conformes aux hypothèses d'un bruit blanc (Ljung-Box : $p = 0{,}595$). Les prévisions hors échantillon reproduisent correctement la tendance générale pour 2021-2023, mais sous-estiment fortement la hausse post-2023, en raison de chocs géopolitiques et monétaires non anticipables par un modèle purement mécanique.

Pour le taux d'épargne des ménages, la non-stationnarité est confirmée malgré la taille réduite de l'échantillon (69 observations). Le modèle ARIMA(3,1,0), retenu par l'AIC, capte les dynamiques auto-régressives de court et moyen terme avec deux paramètres significatifs. Les prévisions montrent une convergence vers un taux d'épargne stable autour de 14-15 %.

Les régressions MCO apportent un éclairage économique complémentaire aux modèles ARIMA. Pour le prix de l'or, le modèle M8 (R^2aj. = 0,805) identifie le cours du pétrole WTI comme principal déterminant ($\beta = +0{,}839$, $p < 0{,}001$) (or et pétrole sont co-déterminés par les anticipations inflationnistes et la demande mondiale en matières premières), suivi du taux de change EUR/USD ($\beta = +2{,}190$, *) qui reflète l'effet dollar sur les prix en monnaie internationale. Pour le taux d'épargne, le modèle M8 (R^2aj. = 0,800) désigne le taux de chômage comme variable dominante ($\beta = -0{,}718$, $p < 0{,}001$), capturant la contrainte de revenu agrégée, avec un rôle complémentaire de l'inflation ($\beta = +0{,}266$, *) via le motif de précaution. Ces résultats sont économiquement interprétables et cohérents avec la théorie. Cependant, la forte autocorrélation des résidus dans les deux cas (DW = 0,628 pour l'or, DW = 0,692 pour l'épargne) indique un risque élevé de régression fallacieuse sur séries I(1) ; une analyse de cointégration et un modèle à correction d'erreur (ECM) seraient nécessaires pour valider la nature structurelle de ces relations.

Ce travail souligne plusieurs limites importantes. Premièrement, les modèles ARIMA extrapolent les régularités passées sans intégrer de théorie économique sous-jacente : ils sont vulnérables aux ruptures structurelles (CUSUM instable en 2008 pour l'or). Deuxièmement, les effets ARCH dans les résidus du modèle or montrent que la variance conditionnelle n'est pas constante, une extension GARCH serait nécessaire pour une modélisation complète. Troisièmement, la série d'épargne, avec seulement 69 observations, limite la puissance des tests statistiques.

En termes de perspectives, plusieurs pistes d'approfondissement sont envisageables : modèles GARCH pour la volatilité de l'or, modèles à correction d'erreur (ECM) si une relation de cointégration est établie entre l'or et ses déterminants macroéconomiques (taux d'intérêt réel, dollar index, inflation), et analyse multivariée (VAR) pour étudier les interactions entre l'épargne, la consommation et le revenu disponible.

Bibliographie

Sources de données

INSEE (2026). Série n° 010002061 : Prix au comptant de l'or, fixing LME après-midi, en dollars par once troy (données mensuelles). Disponible sur : https://www.insee.fr/fr/statistiques/serie/010002061

INSEE (2019). L'épargne des ménages en France, publication réf. 4277790. Disponible sur : https://www.insee.fr/fr/statistiques/4277790?sommaire=4318291

INSEE. Indice des prix à la consommation — séries longues (France, base 1998). Disponible sur : https://www.insee.fr/fr/statistiques/serie/000641194

INSEE. Taux de chômage au sens du BIT, série 001688526 (France métropolitaine, données annuelles). Disponible sur : https://www.insee.fr/fr/statistiques/serie/001688526

INSEE. Comptes nationaux annuels — taux de croissance du PIB en volume (base 2014). Disponible sur : https://www.insee.fr/fr/statistiques/2830677

Federal Reserve Bank of St. Louis — FRED (2024). Federal Funds Effective Rate (FEDFUNDS) ; US CPI All Urban Consumers (CPIAUCSL) ; Crude Oil WTI (DCOILWTICO) ; US/EUR exchange rate (DEXUSEU). Disponible sur : https://fred.stlouisfed.org

Banque de France (2024). Taux des OAT à 10 ans (taux long terme souverain français). Disponible sur : https://www.banque-france.fr/statistiques/taux-et-cours/les-taux-de-rendement-des-emprunts-detat

Annexe : Code R

```
# ================================================================
#  ANALYSE ECONOMETRIQUE - PRIX DE L'OR & EPARGNE DES MENAGES
#  L3 Économie - Cours de Séries Temporelles
# ================================================================

# ---------------------------------------------------------------
# 0. PACKAGES ET THEME GRAPHIQUE
# ---------------------------------------------------------------
library(readxl)
library(forecast)
library(tseries)
library(ggplot2)
library(dplyr)
library(tidyr)
library(scales)

# Création des dossiers de sortie
dir.create("figures",  showWarnings = FALSE)
dir.create("outputs",  showWarnings = FALSE)

# -- Thème personnalisé style INSEE (minimaliste et professionnel) --
theme_insee <- function(base_size = 11) {
  theme_minimal(base_size = base_size) +
    theme(
      plot.title        = element_text(face = "bold", size = base_size + 1,
                                       colour = "#2c3e50", hjust = 0,
                                       margin = margin(b = 6)),
      plot.subtitle     = element_text(size = base_size - 1, colour = "#555555",
                                       hjust = 0, margin = margin(b = 8)),
      plot.caption      = element_text(size = base_size - 2, colour = "#888888",
                                       hjust = 0, margin = margin(t = 8)),
      axis.title        = element_text(size = base_size - 1, colour = "#444444"),
      axis.text         = element_text(size = base_size - 2, colour = "#444444"),
      axis.line.x       = element_line(colour = "#cccccc", linewidth = 0.4),
      axis.ticks        = element_line(colour = "#cccccc", linewidth = 0.3),
      panel.grid.major  = element_line(colour = "#eeeeee", linewidth = 0.4),
      panel.grid.minor  = element_blank(),
      panel.background  = element_rect(fill = "white", colour = NA),
      plot.background   = element_rect(fill = "white", colour = NA),
      legend.position   = "bottom",
      legend.title      = element_blank(),
      legend.text       = element_text(size = base_size - 2),
      legend.key.width  = unit(1.5, "cm"),
      strip.text        = element_text(face = "bold", size = base_size - 1)
    )
}

# Palette de couleurs cohérente
COL_OR      <- "#1a5276"   # bleu foncé - prix de l'or
COL_FIT     <- "#c0392b"   # rouge - ajusté / prévision
COL_REEL    <- "#27ae60"   # vert - valeurs réelles post-2020
COL_EP      <- "#117a65"   # vert foncé - épargne
COL_EPFIN   <- "#a04000"   # marron - épargne financière
COL_CRISIS  <- "#e74c3c"   # rouge crise
COL_SHADE   <- "#d5e8f3"   # bleu clair - zones IC

# Fonction utilitaire : sauvegarder un graphique ggplot
```

```
save_fig <- function(p, nom, w = 22, h = 12) {
  ggsave(filename = paste0("figures/", nom, ".png"),
         plot = p, width = w, height = h, units = "cm", dpi = 150,
         bg = "white")
  invisible(p)
}



# ================================================================
#  PARTIE 1 : PRIX DE L'OR
# ================================================================

# ---------------------------------------------------------------
# 1.1 Lecture et préparation des données
# ---------------------------------------------------------------

raw_or <- read_excel("ST_Or.xlsx", sheet = "valeurs_mensuelles",
                     col_names = FALSE)

# Les données commencent à la ligne 5 ; col 1 = date, col 2 = prix le + récent
data_or <- raw_or[5:nrow(raw_or), 1:2]
colnames(data_or) <- c("date_str", "prix")
data_or$prix <- suppressWarnings(as.numeric(data_or$prix))
data_or <- data_or[!is.na(data_or$prix), ]
data_or$date <- as.Date(paste0(data_or$date_str, "-01"), format = "%Y-%m-%d")
data_or <- data_or[order(data_or$date), ]

# Séparation modélisation (≤ déc. 2020) / post-2020
data_mod  <- data_or[data_or$date <= as.Date("2020-12-01"), ]
data_post <- data_or[data_or$date >  as.Date("2020-12-01"), ]

cat("========================================\n")
cat("DONNEES - PRIX DE L'OR\n")
cat("========================================\n")
cat("Nombre d'observations (1990-2020) :", nrow(data_mod), "\n")
cat("Période :", format(min(data_mod$date), "%b %Y"),
    "à", format(max(data_mod$date), "%b %Y"), "\n\n")

# Statistiques descriptives
s <- data_mod$prix
stats_or <- data.frame(
  Statistique = c("Minimum", "Maximum", "Moyenne", "Médiane", "Écart-type"),
  Valeur_USD  = round(c(min(s), max(s), mean(s), median(s), sd(s)), 2)
)
print(stats_or)

sink("outputs/stats_or.txt")
cat("STATISTIQUES DESCRIPTIVES - PRIX DE L'OR (1990-2020)\n\n")
cat("Nb d'observations :", nrow(data_mod), "\n")
cat("Période :", format(min(data_mod$date), "%b %Y"),
    "à", format(max(data_mod$date), "%b %Y"), "\n\n")
print(stats_or)
sink()

# Séries temporelles R
ts_or     <- ts(data_mod$prix,       start = c(1990, 1), frequency = 12)
ts_log    <- log(ts_or)
ts_dlog   <- diff(ts_log) * 100      # taux de croissance mensuel en %
```

```
# ----------------------------------------------------------------
# 1.2 Graphique 1 - Prix de l'or en niveau (1990-2026)
# ----------------------------------------------------------------

# Évènements à annoter
events <- data.frame(
  date  = as.Date(c("2008-09-01", "2011-09-01", "2020-03-01")),
  label = c("Crise financière\n2008", "Pic historique\n2011", "COVID-19\n2020"),
  ypos  = c(1600, 1920, 1700)
)

fig1 <- ggplot() +
  # Zone hors-échantillon (post-2020)
  annotate("rect",
           xmin = as.Date("2021-01-01"), xmax = max(data_or$date) + 30,
           ymin = -Inf, ymax = Inf,
           fill = "#f0f0f0", alpha = 0.8) +
  annotate("text",
           x = as.Date("2023-01-01"), y = 4800,
           label = "Hors\néchantillon", colour = "#999999",
           size = 3, hjust = 0.5) +
  # Lignes verticales événements
  geom_vline(data = events, aes(xintercept = date),
             linetype = "dashed", colour = COL_CRISIS, linewidth = 0.5) +
  # Série complète
  geom_line(data = data_or, aes(x = date, y = prix),
            colour = COL_OR, linewidth = 0.7) +
  # Annotations événements
  geom_label(data = events, aes(x = date, y = ypos, label = label),
             colour = COL_CRISIS, fill = "white", size = 2.6,
             label.size = 0.2, label.padding = unit(0.2, "lines")) +
  # Ligne de coupure modélisation
  geom_vline(xintercept = as.Date("2021-01-01"),
             linetype = "solid", colour = "#999999", linewidth = 0.6) +
  scale_x_date(date_breaks = "5 years", date_labels = "%Y",
               expand = expansion(mult = c(0.01, 0.01))) +
  scale_y_continuous(labels = label_comma(big.mark = " ", suffix = " $"),
                     expand = expansion(mult = c(0.02, 0.05))) +
  labs(
    title    = "Prix au comptant de l'or (1990-2026)",
    subtitle = "Fixing LME après-midi - en dollars US par once troy",
    x        = NULL,
    y        = "Prix (USD/once)",
    caption  = "Source : Banque de France / LME (via BdF, extraction 2026)"
  ) +
  theme_insee()

save_fig(fig1, "fig1_or_niveau", w = 24, h = 13)
cat("Figure 1 sauvegardée.\n")


# ----------------------------------------------------------------
# 1.3 Graphique 2 - Log du prix de l'or (1990-2020)
# ----------------------------------------------------------------

df_log <- data.frame(date = data_mod$date, log_prix = log(data_mod$prix))
```

```
fig2 <- ggplot(df_log, aes(x = date, y = log_prix)) +
  geom_line(colour = COL_OR, linewidth = 0.75) +
  geom_vline(xintercept = as.Date("2008-09-01"),
             linetype = "dashed", colour = COL_CRISIS, linewidth = 0.5) +
  annotate("text", x = as.Date("2008-09-01"), y = 7.5,
           label = "Crise 2008", colour = COL_CRISIS,
           size = 3, hjust = -0.1) +
  scale_x_date(date_breaks = "5 years", date_labels = "%Y",
               expand = expansion(mult = c(0.01, 0.01))) +
  labs(
    title    = "Prix de l'or en logarithme (1990-2020)",
    subtitle = "Transformation log pour stabiliser la variance",
    x        = NULL,
    y        = "Log(prix)",
    caption  = "Source : Banque de France / LME"
  ) +
  theme_insee()

save_fig(fig2, "fig2_or_log", w = 22, h = 12)
cat("Figure 2 sauvegardée.\n")



# ----------------------------------------------------------------
# 1.4 Graphique 3 - Taux de croissance mensuel (delta log)
# ----------------------------------------------------------------

df_dlog <- data.frame(
  date  = data_mod$date[-1],    # diff réduit d'1 obs
  dlog  = as.numeric(ts_dlog)
)

fig3 <- ggplot(df_dlog, aes(x = date, y = dlog)) +
  geom_hline(yintercept = 0, colour = "#aaaaaa", linewidth = 0.4) +
  geom_line(colour = "#2980b9", linewidth = 0.5) +
  # Zone de crise 2008
  annotate("rect",
           xmin = as.Date("2008-06-01"), xmax = as.Date("2009-06-01"),
           ymin = -Inf, ymax = Inf,
           fill = COL_CRISIS, alpha = 0.08) +
  scale_x_date(date_breaks = "5 years", date_labels = "%Y",
               expand = expansion(mult = c(0.01, 0.01))) +
  scale_y_continuous(labels = label_number(suffix = " %")) +
  labs(
    title    = "Taux de croissance mensuel du prix de l'or (1990-2020)",
    subtitle = "Première différence du logarithme × 100",
    x        = NULL,
    y        = "Variation (%)",
    caption  = "Source : Banque de France / LME - calcul propre"
  ) +
  theme_insee()

save_fig(fig3, "fig3_or_dlog", w = 22, h = 12)
cat("Figure 3 sauvegardée.\n")



# ----------------------------------------------------------------
# 1.5 Tests de stationnarité (ADF + KPSS + PP)
# ----------------------------------------------------------------
```

```
cat("\n========================================\n")
cat("TESTS DE STATIONNARITE - LOG PRIX DE L'OR\n")
cat("========================================\n")

# ADF - en niveau
adf_niv <- adf.test(ts_log, alternative = "stationary", k = 4)
cat("\n-- ADF (4 retards) - Log prix, en niveau --\n")
cat("DF =", round(adf_niv$statistic, 4),
    "| p-valeur =", round(adf_niv$p.value, 4), "\n")
cat("Décision : On ne rejette pas H0 → présence d'une racine unitaire\n")

# ADF - en première différence
adf_diff <- adf.test(ts_dlog, alternative = "stationary", k = 4)
cat("\n-- ADF (4 retards) - Log prix, en différence --\n")
cat("DF =", round(adf_diff$statistic, 4),
    "| p-valeur =", round(adf_diff$p.value, 4), "\n")
cat("Décision : On rejette H0 → la série est stationnaire en différence → I(1)\n")

# KPSS - confirmation
kpss_niv  <- kpss.test(ts_log,  null = "Level")
kpss_diff <- kpss.test(ts_dlog, null = "Level")
cat("\n-- KPSS - en niveau (H0 : stationnaire) --\n")
cat("Stat =", round(kpss_niv$statistic, 4),
    "| p-valeur =", round(kpss_niv$p.value, 4), "\n")
cat("Décision : On rejette H0 → non-stationnaire (confirme ADF)\n")
cat("\n-- KPSS - en différence (H0 : stationnaire) --\n")
cat("Stat =", round(kpss_diff$statistic, 4),
    "| p-valeur =", round(kpss_diff$p.value, 4), "\n")
cat("Décision : On ne rejette pas H0 → stationnaire (confirme d=1)\n")

sink("outputs/tests_statio_or.txt")
cat("TESTS DE STATIONNARITE - LOG PRIX DE L'OR\n\n")
cat("ADF en niveau    : DF =", round(adf_niv$statistic, 4),
    ", p =", round(adf_niv$p.value, 4), "\n")
cat("ADF en diff.     : DF =", round(adf_diff$statistic, 4),
    ", p =", round(adf_diff$p.value, 4), "\n")
cat("KPSS en niveau   : stat =", round(kpss_niv$statistic, 4),
    ", p =", round(kpss_niv$p.value, 4), "\n")
cat("KPSS en diff.    : stat =", round(kpss_diff$statistic, 4),
    ", p =", round(kpss_diff$p.value, 4), "\n")
cat("\nConclusion : série I(1) - on modélise en différence (d=1)\n")
sink()



# ---------------------------------------------------------------
# 1.6 Graphiques 4 & 5 - ACF / PACF
# ---------------------------------------------------------------

# Fonction pour créer un graphe ACF/PACF stylisé avec ggplot
plot_acf_gg <- function(serie, titre, max_lag = 36, color = COL_OR) {
  acf_vals  <- acf(serie,  lag.max = max_lag, plot = FALSE)
  pacf_vals <- pacf(serie, lag.max = max_lag, plot = FALSE)
  ic        <- qnorm(0.975) / sqrt(length(serie))

  df_acf  <- data.frame(lag = as.numeric(acf_vals$lag[-1]),
                        valeur = as.numeric(acf_vals$acf[-1]),
                        type = "ACF")
  df_pacf <- data.frame(lag = as.numeric(pacf_vals$lag),
                        valeur = as.numeric(pacf_vals$acf),
```

```
                         type = "PACF")
  df <- rbind(df_acf, df_pacf)

  ggplot(df, aes(x = lag, y = valeur)) +
    geom_hline(yintercept = 0, colour = "#aaaaaa", linewidth = 0.4) +
    geom_hline(yintercept =  ic, linetype = "dashed",
               colour = COL_CRISIS, linewidth = 0.5) +
    geom_hline(yintercept = -ic, linetype = "dashed",
               colour = COL_CRISIS, linewidth = 0.5) +
    geom_segment(aes(x = lag, xend = lag, y = 0, yend = valeur),
                 colour = color, linewidth = 0.8) +
    geom_point(colour = color, size = 1.2) +
    facet_wrap(~type, nrow = 1) +
    scale_x_continuous(breaks = seq(0, max_lag, by = 6)) +
    scale_y_continuous(limits = c(-0.5, 1),
                       breaks = seq(-0.4, 1, by = 0.2)) +
    labs(title = titre,
         x = "Retard (lag)", y = "Corrélation",
         caption = "Barres en rouge : intervalle de confiance à 95 %") +
    theme_insee() +
    theme(legend.position = "none")
}

fig4 <- plot_acf_gg(ts_log,
                    "ACF et PACF - Log prix de l'or (en niveau, 1990-2020)",
                    color = COL_OR)
save_fig(fig4, "fig4_acf_niveau", w = 22, h = 12)
cat("Figure 4 sauvegardée.\n")

fig5 <- plot_acf_gg(ts_dlog,
                    "ACF et PACF - Taux de croissance de l'or (Δlog, 1990-2020)",
                    color = "#2980b9")
save_fig(fig5, "fig5_acf_diff", w = 22, h = 12)
cat("Figure 5 sauvegardée.\n")



# ----------------------------------------------------------------
# 1.7 Sélection et estimation du modèle ARIMA
# ----------------------------------------------------------------

cat("\n========================================\n")
cat("SELECTION DU MODELE ARIMA - LOG PRIX DE L'OR\n")
cat("========================================\n")

# auto.arima (modèle de référence)
arima_auto <- auto.arima(ts_log,
                         stepwise    = FALSE,
                         approximation = FALSE,
                         ic          = "aic",
                         trace       = FALSE)

p_or <- arima_auto$arma[1]
d_or <- arima_auto$arma[6]
q_or <- arima_auto$arma[2]
cat(sprintf("Modèle sélectionné par auto.arima : ARIMA(%d,%d,%d)\n", p_or, d_or, q_or))
print(summary(arima_auto))

# Test de significativité des coefficients (Student)
coefs    <- coef(arima_auto)
```

```
se_coefs <- sqrt(diag(arima_auto$var.coef))
t_stats  <- coefs / se_coefs
p_vals   <- 2 * (1 - pnorm(abs(t_stats)))
tab_coef <- data.frame(
  Coef     = round(coefs,    4),
  Std_Err  = round(se_coefs, 4),
  t_stat   = round(t_stats,  3),
  p_valeur = round(p_vals,   4)
)
cat("\nTests de Student sur les coefficients :\n")
print(tab_coef)

sink("outputs/arima_or.txt")
cat(sprintf("MODELE ARIMA(%d,%d,%d) - LOG PRIX DE L'OR (1990-2020)\n\n", p_or, d_or, q_or))
print(summary(arima_auto))
cat("\nTests de significativité (Student) :\n")
print(tab_coef)
cat("\nAIC =", round(AIC(arima_auto), 2),
    "| BIC =", round(BIC(arima_auto), 2), "\n")
sink()



# ---------------------------------------------------------------
# 1.8 Graphique 6 – Valeurs ajustées vs observées
# ---------------------------------------------------------------

df_fit <- data.frame(
  date     = data_mod$date,
  observes = data_mod$prix,
  ajustes  = exp(as.numeric(fitted(arima_auto)))
)
df_fit_long <- tidyr::pivot_longer(df_fit, -date,
                                   names_to = "serie",
                                   values_to = "valeur")
df_fit_long$serie <- factor(df_fit_long$serie,
                            levels = c("observes", "ajustes"),
                            labels = c("Valeurs observées", "Valeurs ajustées"))

fig6 <- ggplot(df_fit_long, aes(x = date, y = valeur,
                                colour = serie, linewidth = serie)) +
  geom_line() +
  scale_colour_manual(values = c("Valeurs observées" = COL_OR,
                                 "Valeurs ajustées"  = COL_FIT)) +
  scale_linewidth_manual(values = c("Valeurs observées" = 0.8,
                                    "Valeurs ajustées"  = 0.65)) +
  scale_x_date(date_breaks = "5 years", date_labels = "%Y",
               expand = expansion(mult = c(0.01, 0.01))) +
  scale_y_continuous(labels = label_comma(big.mark = " ", suffix = " $")) +
  labs(
    title    = sprintf("Prévision en échantillon – ARIMA(%d,%d,%d)", p_or, d_or, q_or),
    subtitle = "Prix de l'or (1990-2020) : valeurs observées vs valeurs ajustées",
    x = NULL, y = "Prix (USD/once)",
    caption  = "Source : calcul propre sous R"
  ) +
  theme_insee()

save_fig(fig6, "fig6_arima_fit", w = 22, h = 12)
cat("Figure 6 sauvegardée.\n")
```

```
# ----------------------------------------------------------------
# 1.9 Diagnostic des résidus
# ----------------------------------------------------------------

res_or <- as.numeric(residuals(arima_auto))
lb_or  <- Box.test(res_or, lag = 12, type = "Ljung-Box")

cat("\n========================================\n")
cat("DIAGNOSTIC DES RESIDUS - OR\n")
cat("========================================\n")
cat("Moyenne des résidus      :", round(mean(res_or), 6), "\n")
cat("Écart-type des résidus   :", round(sd(res_or),   6), "\n")
cat("Test de Ljung-Box (L=12) : X² =", round(lb_or$statistic, 4),
    "| p =", round(lb_or$p.value, 4), "\n")
cat("Décision : pas d'autocorrélation résiduelle (modèle bien spécifié)\n")

sink("outputs/residus_or.txt")
cat("DIAGNOSTIC DES RESIDUS ARIMA - PRIX DE L'OR\n\n")
cat("Moyenne :", round(mean(res_or), 6), "\n")
cat("Ecart-type :", round(sd(res_or), 6), "\n")
cat("Test Ljung-Box (lag=12) : X² =", round(lb_or$statistic, 4),
    ", p =", round(lb_or$p.value, 4), "\n")
sink()

# Graphique diagnostics résidus (4 panels)
df_res <- data.frame(
  date   = data_mod$date,
  residu = res_or
)

# Panel A : résidus dans le temps
p_res_time <- ggplot(df_res, aes(x = date, y = residu)) +
  geom_hline(yintercept = 0, colour = "#aaaaaa") +
  geom_line(colour = COL_OR, linewidth = 0.5) +
  labs(title = "Résidus dans le temps", x = NULL, y = "Résidus") +
  theme_insee()

# Panel B : ACF des résidus
acf_res  <- acf(res_or,  lag.max = 24, plot = FALSE)
ic_res   <- qnorm(0.975) / sqrt(length(res_or))
df_acfr  <- data.frame(lag = as.numeric(acf_res$lag[-1]),
                       val = as.numeric(acf_res$acf[-1]))
p_acf_res <- ggplot(df_acfr, aes(x = lag, y = val)) +
  geom_hline(yintercept = 0, colour = "#aaaaaa") +
  geom_hline(yintercept =  ic_res, linetype="dashed", colour=COL_CRISIS, linewidth=0.5) +
  geom_hline(yintercept = -ic_res, linetype="dashed", colour=COL_CRISIS, linewidth=0.5) +
  geom_segment(aes(xend = lag, y = 0, yend = val), colour = COL_OR, linewidth = 0.8) +
  geom_point(colour = COL_OR, size = 1.2) +
  labs(title = "ACF des résidus", x = "Retard", y = "Corrélation") +
  theme_insee()

# Panel C : histogramme des résidus
p_hist_res <- ggplot(df_res, aes(x = residu)) +
  geom_histogram(aes(y = after_stat(density)), bins = 25,
                 fill = COL_SHADE, colour = "white") +
  stat_function(fun = dnorm,
                args = list(mean = mean(res_or), sd = sd(res_or)),
                colour = COL_FIT, linewidth = 0.8) +
```

```
  labs(title = "Distribution des résidus", x = "Résidus", y = "Densité") +
  theme_insee()

# Panel D : QQ-plot
df_qq <- data.frame(
  theorique  = qnorm(ppoints(length(res_or))),
  empirique  = sort(res_or)
)
p_qq <- ggplot(df_qq, aes(x = theorique, y = empirique)) +
  geom_abline(slope = sd(res_or), intercept = mean(res_or),
              colour = COL_FIT, linewidth = 0.8) +
  geom_point(colour = COL_OR, size = 1.2, alpha = 0.7) +
  labs(title = "QQ-plot des résidus",
       x = "Quantiles théoriques", y = "Quantiles empiriques") +
  theme_insee()

library(gridExtra)
fig7 <- grid.arrange(p_res_time, p_acf_res, p_hist_res, p_qq, ncol = 2,
                     top = grid::textGrob(
                       sprintf("Diagnostic des résidus - ARIMA(%d,%d,%d)",
                               p_or, d_or, q_or),
                       gp = grid::gpar(fontsize = 12, fontface = "bold",
                                       col = "#2c3e50")))
ggsave("figures/fig7_residus.png", fig7,
       width = 24, height = 16, units = "cm", dpi = 150, bg = "white")
cat("Figure 7 sauvegardée.\n")



# ----------------------------------------------------------------
# 1.10 Prévisions hors échantillon (2021-2025)
# ----------------------------------------------------------------

h_prev   <- 60   # 5 ans = 60 mois
prev_or  <- forecast(arima_auto, h = h_prev, level = c(80, 95))

dates_prev <- seq(as.Date("2021-01-01"), by = "month", length.out = h_prev)

# Reconstruction du data.frame pour ggplot
df_prev <- data.frame(
  date   = dates_prev,
  centre = exp(as.numeric(prev_or$mean)),
  lo80   = exp(as.numeric(prev_or$lower[, 1])),
  hi80   = exp(as.numeric(prev_or$upper[, 1])),
  lo95   = exp(as.numeric(prev_or$lower[, 2])),
  hi95   = exp(as.numeric(prev_or$upper[, 2]))
)

# Données réelles post-2020 disponibles (jusqu'à fin 2025)
data_reel_post <- data_or[data_or$date > as.Date("2020-12-01") &
                            data_or$date <= as.Date("2025-12-01"), ]

# Données observées récentes pour le graphique (à partir de 2015)
data_recents <- data_mod[data_mod$date >= as.Date("2015-01-01"), ]

fig8 <- ggplot() +
  # IC 95%
  geom_ribbon(data = df_prev,
              aes(x = date, ymin = lo95, ymax = hi95),
```

```
              fill = COL_SHADE, alpha = 0.6) +
  # IC 80%
  geom_ribbon(data = df_prev,
              aes(x = date, ymin = lo80, ymax = hi80),
              fill = "#a8d4f0", alpha = 0.6) +
  # Série observée 2015-2020
  geom_line(data = data_recents,
            aes(x = date, y = prix, colour = "Observé (≤ 2020)"),
            linewidth = 0.9) +
  # Prévision centrale
  geom_line(data = df_prev,
            aes(x = date, y = centre, colour = "Prévision ARIMA"),
            linewidth = 0.85, linetype = "dashed") +
  # Valeurs réelles post-2020
  geom_line(data = data_reel_post,
            aes(x = date, y = prix, colour = "Réel post-2020"),
            linewidth = 0.9) +
  geom_vline(xintercept = as.Date("2021-01-01"),
             linetype = "dotted", colour = "#777777", linewidth = 0.6) +
  scale_colour_manual(
    values = c("Observé (≤ 2020)" = COL_OR,
               "Prévision ARIMA"  = COL_FIT,
               "Réel post-2020"   = COL_REEL)
  ) +
  scale_x_date(date_breaks = "1 year", date_labels = "%Y",
               expand = expansion(mult = c(0.01, 0.01))) +
  scale_y_continuous(labels = label_comma(big.mark = " ", suffix = " $")) +
  labs(
    title    = sprintf("Prévisions hors échantillon du prix de l'or (2021-2025) -
ARIMA(%d,%d,%d)",
                       p_or, d_or, q_or),
    subtitle = "Fan chart avec intervalles de confiance à 80 % et 95 %",
    x = NULL, y = "Prix (USD/once)",
    caption  = "Zones ombrées : IC 80 % (foncé) et IC 95 % (clair) | Source : calcul propre"
  ) +
  theme_insee()

save_fig(fig8, "fig8_previsions", w = 26, h = 13)
cat("Figure 8 sauvegardée.\n")

# Tableau comparatif
prev_df_ann  <- df_prev %>%
  mutate(annee = format(date, "%Y")) %>%
  group_by(annee) %>%
  summarise(prev_moy = round(mean(centre), 0), .groups = "drop")

reel_df_ann  <- data_reel_post %>%
  mutate(annee = format(date, "%Y")) %>%
  group_by(annee) %>%
  summarise(reel_moy = round(mean(prix),   0), .groups = "drop")

cmp <- merge(prev_df_ann, reel_df_ann, by = "annee", all.x = TRUE)
cmp$ecart_pct <- round((cmp$reel_moy - cmp$prev_moy) / cmp$prev_moy * 100, 1)
cat("\nComparaison prévisions vs valeurs réelles :\n")
print(cmp)
sink("outputs/comparaison_prev.txt")
cat("COMPARAISON PREVISIONS vs VALEURS REELLES\n\n")
print(cmp)
sink()
```

```
# ================================================================
#  PARTIE 2 : TAUX D'EPARGNE DES MENAGES (France, 1950-2018)
# ================================================================

cat("\n\n========================================\n")
cat("PARTIE 2 : EPARGNE DES MENAGES\n")
cat("========================================\n")

# ---------------------------------------------------------------
# 2.1 Lecture des données (Figure 4 = série temporelle annuelle)
# ---------------------------------------------------------------

raw_ep <- read_excel("Epargne_Menage.xlsx", sheet = "Figure 4",
                     col_names = FALSE)
data_ep <- as.data.frame(raw_ep[5:73, 1:4])
colnames(data_ep) <- c("annee", "tx_brut", "tx_invest", "tx_fin")
data_ep[] <- lapply(data_ep, as.numeric)
data_ep   <- data_ep[!is.na(data_ep$annee), ]

cat("Nombre d'observations :", nrow(data_ep), "\n")
cat("Période :", min(data_ep$annee), "à", max(data_ep$annee), "\n")

stats_ep <- data.frame(
  Statistique = c("Minimum", "Maximum", "Moyenne", "Médiane", "Écart-type"),
  Taux_brut   = round(c(min(data_ep$tx_brut), max(data_ep$tx_brut),
                        mean(data_ep$tx_brut), median(data_ep$tx_brut),
                        sd(data_ep$tx_brut)), 2)
)
cat("\nStatistiques descriptives du taux d'épargne brut (%) :\n")
print(stats_ep)

sink("outputs/stats_epargne.txt")
cat("STATISTIQUES - TAUX D'EPARGNE (France, 1950-2018)\n\n")
print(stats_ep)
sink()

ts_ep   <- ts(data_ep$tx_brut, start = 1950, frequency = 1)
ts_ep_d <- diff(ts_ep)



# ---------------------------------------------------------------
# 2.2 Graphique 9 – Taux d'épargne en niveau et financière
# ---------------------------------------------------------------

df_ep_long <- tidyr::pivot_longer(
  data_ep[, c("annee", "tx_brut", "tx_fin")],
  cols = c("tx_brut", "tx_fin"),
  names_to  = "serie",
  values_to = "valeur"
)
df_ep_long$serie <- factor(df_ep_long$serie,
                           levels = c("tx_brut", "tx_fin"),
                           labels = c("Taux d'épargne brut",
                                      "dont : épargne financière"))


events_ep <- data.frame(
  annee = c(1973, 1979, 2008),
```

```
  label = c("1er choc\npétrolier", "2e choc\npétrolier", "Crise\n2008")
)

fig9 <- ggplot(df_ep_long, aes(x = annee, y = valeur,
                               colour = serie, linetype = serie)) +
  geom_line(linewidth = 0.8) +
  geom_vline(data = events_ep, aes(xintercept = annee),
             linetype = "dotted", colour = COL_CRISIS, linewidth = 0.5) +
  geom_text(data = events_ep,
            aes(x = annee, y = 21.5, label = label),
            colour = COL_CRISIS, size = 2.6, hjust = 0.5,
            inherit.aes = FALSE) +
  scale_colour_manual(values = c("Taux d'épargne brut"       = COL_EP,
                                 "dont : épargne financière"  = COL_EPFIN)) +
  scale_linetype_manual(values = c("Taux d'épargne brut"       = "solid",
                                   "dont : épargne financière"  = "dashed")) +
  scale_x_continuous(breaks = seq(1950, 2020, by = 10)) +
  scale_y_continuous(labels = label_number(suffix = " %"),
                     limits = c(0, 23)) +
  labs(
    title    = "Taux d'épargne des ménages en France (1950-2018)",
    subtitle = "En pourcentage du revenu disponible brut",
    x = NULL, y = "Taux d'épargne (%)",
    caption  = "Source : INSEE, comptes nationaux, base 2014"
  ) +
  theme_insee()

save_fig(fig9, "fig9_epargne_niveau", w = 22, h = 12)
cat("Figure 9 sauvegardée.\n")



# ----------------------------------------------------------------
# 2.3 Graphique 10 - Variation annuelle du taux d'épargne
# ----------------------------------------------------------------

df_ep_diff <- data.frame(
  annee = data_ep$annee[-1],
  delta = as.numeric(ts_ep_d)
)

fig10 <- ggplot(df_ep_diff, aes(x = annee, y = delta)) +
  geom_hline(yintercept = 0, colour = "#aaaaaa", linewidth = 0.4) +
  geom_col(aes(fill = delta > 0), width = 0.7, show.legend = FALSE) +
  scale_fill_manual(values = c("TRUE" = COL_EP, "FALSE" = COL_FIT)) +
  scale_x_continuous(breaks = seq(1950, 2020, by = 10)) +
  scale_y_continuous(labels = label_number(suffix = " pp")) +
  labs(
    title    = "Variation annuelle du taux d'épargne brut (1951-2018)",
    subtitle = "Première différence - en points de pourcentage",
    x = NULL, y = "Variation (pp)",
    caption  = "Source : INSEE, comptes nationaux, base 2014"
  ) +
  theme_insee()

save_fig(fig10, "fig10_epargne_diff", w = 22, h = 12)
cat("Figure 10 sauvegardée.\n")



# ----------------------------------------------------------------
```

```
# 2.4 Tests de stationnarité – Épargne
# ----------------------------------------------------------------

cat("\n========================================\n")
cat("TESTS DE STATIONNARITE - TAUX D'EPARGNE\n")
cat("========================================\n")

adf_ep_niv  <- adf.test(ts_ep,   alternative = "stationary", k = 3)
adf_ep_diff <- adf.test(ts_ep_d, alternative = "stationary", k = 3)
kpss_ep_niv <- kpss.test(ts_ep,  null = "Level")

cat("ADF en niveau (k=3) : DF =", round(adf_ep_niv$statistic,  4),
    "| p =", round(adf_ep_niv$p.value,  4), "\n")
cat("ADF en diff.  (k=3) : DF =", round(adf_ep_diff$statistic, 4),
    "| p =", round(adf_ep_diff$p.value, 4), "\n")
cat("KPSS en niveau      : stat =", round(kpss_ep_niv$statistic, 4),
    "| p =", round(kpss_ep_niv$p.value, 4), "\n")

cat("\nNote : avec seulement 69 obs annuelles, la puissance des tests ADF\n")
cat("est limitée. La série présente un fort pic structurel (années 1970).\n")
cat("L'inspection visuelle et le KPSS suggèrent une non-stationnarité en niveau.\n")
cat("On retient d=1 conformément à auto.arima.\n")

sink("outputs/tests_statio_ep.txt")
cat("TESTS DE STATIONNARITE - TAUX D'EPARGNE\n\n")
cat("ADF en niveau : DF =", round(adf_ep_niv$statistic, 4),
    ", p =", round(adf_ep_niv$p.value, 4), "\n")
cat("ADF en diff.  : DF =", round(adf_ep_diff$statistic, 4),
    ", p =", round(adf_ep_diff$p.value, 4), "\n")
cat("KPSS niveau   : stat =", round(kpss_ep_niv$statistic, 4),
    ", p =", round(kpss_ep_niv$p.value, 4), "\n\n")
cat("Note : puissance limitée (n=69). On retient d=1 (auto.arima).\n")
sink()



# ----------------------------------------------------------------
# 2.5 Graphique 11 – ACF/PACF épargne
# ----------------------------------------------------------------

fig11 <- plot_acf_gg(ts_ep,
                     "ACF et PACF – Taux d'épargne brut (en niveau, 1950-2018)",
                     max_lag = 20, color = COL_EP)
save_fig(fig11, "fig11_acf_epargne", w = 22, h = 12)
cat("Figure 11 sauvegardée.\n")



# ----------------------------------------------------------------
# 2.6 Modèle ARIMA – Épargne
# ----------------------------------------------------------------

cat("\n========================================\n")
cat("MODELE ARIMA - TAUX D'EPARGNE\n")
cat("========================================\n")

arima_ep <- auto.arima(ts_ep, stepwise = FALSE, approximation = FALSE,
                       ic = "aic", trace = FALSE)
p_ep <- arima_ep$arma[1]
d_ep <- arima_ep$arma[6]
```

```
q_ep <- arima_ep$arma[2]
cat(sprintf("Modèle sélectionné : ARIMA(%d,%d,%d)\n", p_ep, d_ep, q_ep))
print(summary(arima_ep))

# Comparaison de quelques modèles concurrents
arima_110 <- Arima(ts_ep, order = c(1, 1, 0))
arima_210 <- Arima(ts_ep, order = c(2, 1, 0))
arima_011 <- Arima(ts_ep, order = c(0, 1, 1))

tab_comp <- data.frame(
  Modele = c("ARIMA(1,1,0)", "ARIMA(2,1,0)", "ARIMA(3,1,0)",
             "ARIMA(0,1,1)"),
  AIC    = round(c(AIC(arima_110), AIC(arima_210), AIC(arima_ep), AIC(arima_011)), 2),
  BIC    = round(c(BIC(arima_110), BIC(arima_210), BIC(arima_ep), BIC(arima_011)), 2)
)
cat("\nComparaison de modèles candidats :\n")
print(tab_comp)

# Tests Student coefficients
coefs_ep  <- coef(arima_ep)
se_ep     <- sqrt(diag(arima_ep$var.coef))
t_ep      <- coefs_ep / se_ep
pv_ep     <- 2 * (1 - pnorm(abs(t_ep)))
tab_coef_ep <- data.frame(
  Coef     = round(coefs_ep, 4),
  Std_Err  = round(se_ep,    4),
  t_stat   = round(t_ep,     3),
  p_valeur = round(pv_ep,    4)
)
cat("\nTests de Student :\n")
print(tab_coef_ep)

# Diagnostic résidus
res_ep <- residuals(arima_ep)
lb_ep  <- Box.test(res_ep, lag = 10, type = "Ljung-Box")
cat("\nLjung-Box (L=10) : X² =", round(lb_ep$statistic, 4),
    "| p =", round(lb_ep$p.value, 4), "\n")

sink("outputs/arima_epargne.txt")
cat(sprintf("MODELE ARIMA(%d,%d,%d) - TAUX D'EPARGNE\n\n", p_ep, d_ep, q_ep))
print(summary(arima_ep))
cat("\nComparaison modèles :\n"); print(tab_comp)
cat("\nTests Student :\n"); print(tab_coef_ep)
cat("\nLjung-Box (L=10) : X² =", round(lb_ep$statistic, 4),
    ", p =", round(lb_ep$p.value, 4), "\n")
sink()



# ---------------------------------------------------------------
# 2.7 Graphique 12 - Prévisions taux d'épargne
# ---------------------------------------------------------------

prev_ep     <- forecast(arima_ep, h = 10, level = c(80, 95))
dates_ep_pr <- 2019:2028

df_prev_ep <- data.frame(
  annee  = dates_ep_pr,
  centre = as.numeric(prev_ep$mean),
  lo80   = as.numeric(prev_ep$lower[, 1]),
```

```
  hi80   = as.numeric(prev_ep$upper[, 1]),
  lo95   = as.numeric(prev_ep$lower[, 2]),
  hi95   = as.numeric(prev_ep$upper[, 2])
)

# Données historiques pour contexte
df_ep_hist <- data.frame(annee = data_ep$annee,
                         valeur = data_ep$tx_brut)

fig12 <- ggplot() +
  # Historique
  geom_line(data = df_ep_hist,
            aes(x = annee, y = valeur, colour = "Observé"),
            linewidth = 0.8) +
  # IC 95 %
  geom_ribbon(data = df_prev_ep,
              aes(x = annee, ymin = lo95, ymax = hi95),
              fill = "#c8e6c9", alpha = 0.5) +
  # IC 80 %
  geom_ribbon(data = df_prev_ep,
              aes(x = annee, ymin = lo80, ymax = hi80),
              fill = "#81c784", alpha = 0.5) +
  # Prévision centrale
  geom_line(data = df_prev_ep,
            aes(x = annee, y = centre, colour = "Prévision"),
            linewidth = 0.85, linetype = "dashed") +
  geom_vline(xintercept = 2018.5, linetype = "dotted",
             colour = "#777777", linewidth = 0.6) +
  scale_colour_manual(values = c("Observé"   = COL_EP,
                                 "Prévision" = "#1b5e20")) +
  scale_x_continuous(breaks = seq(1950, 2028, by = 10)) +
  scale_y_continuous(labels = label_number(suffix = " %")) +
  labs(
    title    = sprintf("Prévisions du taux d'épargne (2019-2028) - ARIMA(%d,%d,%d)",
                       p_ep, d_ep, q_ep),
    subtitle = "Fan chart avec IC à 80 % et 95 %",
    x = NULL, y = "Taux d'épargne brut (%)",
    caption  = "Source : INSEE / calcul propre"
  ) +
  theme_insee()

save_fig(fig12, "fig12_prev_epargne", w = 22, h = 12)
cat("Figure 12 sauvegardée.\n")



# ================================================================
#  PARTIE 3 : COMPARAISON INTERNATIONALE (données panel)
# ================================================================

cat("\n========================================\n")
cat("PARTIE 3 : COMPARAISON INTERNATIONALE\n")
cat("========================================\n")

raw_f3 <- read_excel("Epargne_Menage.xlsx", sheet = "Figure 3",
                     col_names = FALSE)
pays    <- as.character(raw_f3[5:19, 1, drop = TRUE])
vals    <- suppressWarnings(
  as.data.frame(lapply(raw_f3[5:19, 2:6], as.numeric))
)
```

```
colnames(vals) <- c("y2000", "y2005", "y2010", "y2015", "y2018")
panel           <- cbind(data.frame(pays = pays), vals)
panel           <- panel[complete.cases(panel[, c("y2000", "y2018")]), ]
cat("Panel :", nrow(panel), "pays × 5 périodes\n")
print(panel[, c("pays", "y2000", "y2018")])

# Régression cross-section : taux 2018 ~ taux 2000
ols_panel <- lm(y2018 ~ y2000, data = panel)
cat("\nOLS cross-section (taux 2018 ~ taux 2000) :\n")
print(summary(ols_panel))

# Graphique panel
fig_panel <- ggplot(panel, aes(x = y2000, y = y2018, label = pays)) +
  geom_abline(slope = 1, intercept = 0, linetype = "dotted",
              colour = "#aaaaaa") +
  geom_smooth(method = "lm", se = TRUE, colour = COL_FIT,
              fill = COL_SHADE, alpha = 0.3, linewidth = 0.8) +
  geom_point(colour = COL_OR, size = 2.5) +
  ggrepel::geom_text_repel(size = 3, colour = "#333333",
                           max.overlaps = 15) +
  scale_x_continuous(labels = label_number(suffix = " %")) +
  scale_y_continuous(labels = label_number(suffix = " %")) +
  labs(
    title    = "Persistance du taux d'épargne en Europe (2000 vs 2018)",
    subtitle = "Régression cross-section - taux 2018 en fonction du taux 2000",
    x = "Taux d'épargne 2000 (%)", y = "Taux d'épargne 2018 (%)",
    caption  = "Source : Eurostat | Diagonale en pointillés : taux 2000 = taux 2018"
  ) +
  theme_insee()

# Vérifier si ggrepel est dispo
if (requireNamespace("ggrepel", quietly = TRUE)) {
  save_fig(fig_panel, "fig_panel", w = 18, h = 16)
  cat("Figure panel sauvegardée.\n")
} else {
  fig_panel2 <- fig_panel +
    geom_text(size = 2.8, colour = "#333333", vjust = -0.8)
  save_fig(fig_panel2, "fig_panel", w = 18, h = 16)
  cat("Figure panel sauvegardée (sans ggrepel).\n")
}



# ==================================================================
#  PARTIE 4 : REGRESSIONS MCO - OR ET EPARGNE (SEPAREES)
# ==================================================================

library(lmtest)

# ------------------------------------------------------------------
# 4.1 MCO - Prix de l'or (1990-2020)
# ------------------------------------------------------------------

cat("\n========================================\n")
cat("PARTIE 4.1 : REGRESSION MCO - PRIX DE L'OR\n")
cat("========================================\n")

# Données annuelles du prix de l'or (1990-2020)
data_or_ann <- data_or %>%
  mutate(annee = as.integer(format(date, "%Y"))) %>%
```

```
  group_by(annee) %>%
  summarise(prix_moy = mean(prix, na.rm = TRUE), .groups = "drop") %>%
  filter(annee >= 1990, annee <= 2020)

data_or_ann$log_or   <- log(data_or_ann$prix_moy)
data_or_ann$tendance  <- data_or_ann$annee - 1990   # tendance : 0 en 1990

# Variables muettes pour crises majeures
data_or_ann$D_2001 <- as.integer(data_or_ann$annee %in% 2001:2002)  # bulle internet + 11-Sept
data_or_ann$D_2008 <- as.integer(data_or_ann$annee %in% 2008:2009)  # crise financière globale
data_or_ann$D_2020 <- as.integer(data_or_ann$annee == 2020)          # COVID-19

cat("Nombre d'observations :", nrow(data_or_ann), "(1990-2020)\n\n")

# Modèles emboîtés
ols_or1 <- lm(log_or ~ tendance,                          data = data_or_ann)
ols_or2 <- lm(log_or ~ tendance + D_2008,                 data = data_or_ann)
ols_or3 <- lm(log_or ~ tendance + D_2001 + D_2008 + D_2020, data = data_or_ann)

cat("OLS Or 1 - log(or) ~ tendance :\n");          print(summary(ols_or1))
cat("\nOLS Or 2 - log(or) ~ tendance + D_2008 :\n"); print(summary(ols_or2))
cat("\nOLS Or 3 - log(or) ~ tendance + 3 crises :\n"); print(summary(ols_or3))

bp_or2 <- bptest(ols_or2)
dw_or2 <- dwtest(ols_or2)
cat("\nBreusch-Pagan (OLS Or 2) :\n"); print(bp_or2)
cat("\nDurbin-Watson (OLS Or 2) :\n"); print(dw_or2)

# Tableau comparatif des modèles
tab_ols_or <- data.frame(
  Modele = c("Modele 1 : tendance seule",
             "Modele 2 : + D_2008",
             "Modele 3 : + D_2001 + D_2008 + D_2020"),
  R2adj  = round(c(summary(ols_or1)$adj.r.squared,
                   summary(ols_or2)$adj.r.squared,
                   summary(ols_or3)$adj.r.squared), 4),
  AIC    = round(c(AIC(ols_or1), AIC(ols_or2), AIC(ols_or3)), 2)
)
cat("\nComparaison modeles (or) :\n"); print(tab_ols_or)

sink("outputs/ols_or.txt")
cat("REGRESSION MCO - PRIX DE L'OR (1990-2020)\n\n")
cat("OLS 1 :\n"); print(summary(ols_or1))
cat("\nOLS 2 :\n"); print(summary(ols_or2))
cat("\nOLS 3 :\n"); print(summary(ols_or3))
cat("\nComparaison modeles :\n"); print(tab_ols_or)
cat("\nBreusch-Pagan (OLS 2) :\n"); print(bp_or2)
cat("\nDurbin-Watson (OLS 2) :\n"); print(dw_or2)
sink()

# Figure MCO or - ajustement + résidus
fig_mco_or_a <- ggplot(data_or_ann, aes(x = annee, y = log_or)) +
  geom_point(colour = COL_OR, size = 2.5) +
  geom_line(aes(y = fitted(ols_or2)), colour = COL_FIT,
            linewidth = 0.9, linetype = "dashed") +
  annotate("rect", xmin = 2007.5, xmax = 2009.5,
           ymin = -Inf, ymax = Inf, fill = COL_CRISIS, alpha = 0.08) +
  annotate("text", x = 2008.5, y = max(data_or_ann$log_or) * 0.985,
           label = "Crise 2008", colour = COL_CRISIS, size = 2.8) +
```

```
  scale_x_continuous(breaks = seq(1990, 2020, by = 5)) +
  labs(title = "MCO : log(prix or) ~ tendance + D_2008 (1990-2020)",
       x = "Annee", y = "Log(prix or, USD/once)",
       caption = "Source : INSEE, serie n 010002061 - calcul propre") +
  theme_insee()

df_res_or2 <- data.frame(annee = data_or_ann$annee, res = residuals(ols_or2))
fig_mco_or_b <- ggplot(df_res_or2, aes(x = annee, y = res)) +
  geom_hline(yintercept = 0, colour = "#aaaaaa") +
  geom_line(colour = COL_OR, linewidth = 0.6) +
  geom_point(colour = COL_OR, size = 1.8) +
  scale_x_continuous(breaks = seq(1990, 2020, by = 5)) +
  labs(title = "Residus MCO (or)", x = "Annee", y = "Residus") +
  theme_insee()

fig_mco_or <- grid.arrange(fig_mco_or_a, fig_mco_or_b, ncol = 2,
  top = grid::textGrob("Regression MCO - Prix de l'or (1990-2020)",
    gp = grid::gpar(fontsize = 12, fontface = "bold", col = "#2c3e50")))
ggsave("figures/fig_mco_or.png", fig_mco_or,
       width = 24, height = 13, units = "cm", dpi = 150, bg = "white")
cat("Figure MCO or sauvegardee.\n")



# ----------------------------------------------------------------
# 4.2 MCO - Taux d'épargne (1950-2018)
# ----------------------------------------------------------------

cat("\n========================================\n")
cat("PARTIE 4.2 : REGRESSION MCO - TAUX D'EPARGNE\n")
cat("========================================\n")

data_ep_mco <- data_ep
data_ep_mco$tendance <- data_ep_mco$annee - 1984   # centré sur 1984

# Variables muettes pour chocs structurels
data_ep_mco$D_1974 <- as.integer(data_ep_mco$annee %in% 1974:1976)  # 1er choc pétrolier
data_ep_mco$D_1979 <- as.integer(data_ep_mco$annee %in% 1980:1982)  # 2e choc pétrolier
data_ep_mco$D_2008 <- as.integer(data_ep_mco$annee %in% 2008:2010)  # crise financière

cat("Nombre d'observations :", nrow(data_ep_mco), "(1950-2018)\n\n")

ols_ep1 <- lm(tx_brut ~ tendance,                              data = data_ep_mco)
ols_ep2 <- lm(tx_brut ~ tendance + D_1974 + D_1979,           data = data_ep_mco)
ols_ep3 <- lm(tx_brut ~ tendance + D_1974 + D_1979 + D_2008,  data = data_ep_mco)

cat("OLS Ep 1 - tx_brut ~ tendance :\n");            print(summary(ols_ep1))
cat("\nOLS Ep 2 - tx_brut ~ tendance + D74 + D79 :\n"); print(summary(ols_ep2))
cat("\nOLS Ep 3 - tx_brut ~ tendance + 3 crises :\n"); print(summary(ols_ep3))

bp_ep3 <- bptest(ols_ep3)
dw_ep3 <- dwtest(ols_ep3)
cat("\nBreusch-Pagan (OLS Ep 3) :\n"); print(bp_ep3)
cat("\nDurbin-Watson (OLS Ep 3) :\n"); print(dw_ep3)

tab_ols_ep <- data.frame(
  Modele = c("Modele 1 : tendance seule",
             "Modele 2 : + D_1974 + D_1979",
             "Modele 3 : + D_1974 + D_1979 + D_2008"),
```

```
  R2adj  = round(c(summary(ols_ep1)$adj.r.squared,
                   summary(ols_ep2)$adj.r.squared,
                   summary(ols_ep3)$adj.r.squared), 4),
  AIC    = round(c(AIC(ols_ep1), AIC(ols_ep2), AIC(ols_ep3)), 2)
)
cat("\nComparaison modeles (epargne) :\n"); print(tab_ols_ep)

sink("outputs/ols_ep.txt")
cat("REGRESSION MCO - TAUX D'EPARGNE (1950-2018)\n\n")
cat("OLS 1 :\n"); print(summary(ols_ep1))
cat("\nOLS 2 :\n"); print(summary(ols_ep2))
cat("\nOLS 3 :\n"); print(summary(ols_ep3))
cat("\nComparaison modeles :\n"); print(tab_ols_ep)
cat("\nBreusch-Pagan (OLS 3) :\n"); print(bp_ep3)
cat("\nDurbin-Watson (OLS 3) :\n"); print(dw_ep3)
sink()

# Figure MCO épargne
fig_mco_ep_a <- ggplot(data_ep_mco, aes(x = annee, y = tx_brut)) +
  geom_point(colour = COL_EP, size = 2.0) +
  geom_line(aes(y = fitted(ols_ep3)), colour = COL_FIT,
            linewidth = 0.9, linetype = "dashed") +
  annotate("rect", xmin = 1973.5, xmax = 1976.5,
           ymin = -Inf, ymax = Inf, fill = COL_CRISIS, alpha = 0.07) +
  annotate("rect", xmin = 1979.5, xmax = 1982.5,
           ymin = -Inf, ymax = Inf, fill = COL_CRISIS, alpha = 0.07) +
  annotate("rect", xmin = 2007.5, xmax = 2010.5,
           ymin = -Inf, ymax = Inf, fill = "#2980b9", alpha = 0.07) +
  scale_x_continuous(breaks = seq(1950, 2018, by = 10)) +
  scale_y_continuous(labels = label_number(suffix = " %")) +
  labs(title = "MCO : taux epargne ~ tendance + chocs (1950-2018)",
       x = "Annee", y = "Taux d'epargne brut (%)",
       caption = "Source : INSEE (ref. 4277790) - calcul propre") +
  theme_insee()

df_res_ep3 <- data.frame(annee = data_ep_mco$annee, res = residuals(ols_ep3))
fig_mco_ep_b <- ggplot(df_res_ep3, aes(x = annee, y = res)) +
  geom_hline(yintercept = 0, colour = "#aaaaaa") +
  geom_line(colour = COL_EP, linewidth = 0.6) +
  geom_point(colour = COL_EP, size = 1.5) +
  scale_x_continuous(breaks = seq(1950, 2018, by = 10)) +
  labs(title = "Residus MCO (epargne)", x = "Annee", y = "Residus (pp)") +
  theme_insee()

fig_mco_ep <- grid.arrange(fig_mco_ep_a, fig_mco_ep_b, ncol = 2,
  top = grid::textGrob("Regression MCO - Taux d'epargne (1950-2018)",
    gp = grid::gpar(fontsize = 12, fontface = "bold", col = "#2c3e50")))
ggsave("figures/fig_mco_ep.png", fig_mco_ep,
       width = 24, height = 13, units = "cm", dpi = 150, bg = "white")
cat("Figure MCO epargne sauvegardee.\n")

cat("\n\n=== SCRIPT TERMINE ===\n")
cat("Figures : ./figures/\n")
cat("Outputs : ./outputs/\n")



# ================================================================
#  FICHIER : mco_macro.R
```

```
# ================================================================

# ================================================================
#  MCO AVEC VARIABLES MACROECONOMIQUES
#  Prix de l'or & Taux d'épargne des ménages
#  Sources : FRED/BLS (données US), INSEE/OCDE (données France)
# ================================================================

library(ggplot2)
library(dplyr)
library(tidyr)
library(scales)
library(lmtest)
library(gridExtra)
library(readxl)

# Thème graphique (identique à analyse_complete.R)
theme_insee <- function(base_size = 11) {
  theme_minimal(base_size = base_size) +
    theme(
      plot.title        = element_text(face = "bold", size = base_size + 1,
                                       colour = "#2c3e50", hjust = 0,
                                       margin = margin(b = 6)),
      plot.subtitle     = element_text(size = base_size - 1, colour = "#555555",
                                       hjust = 0, margin = margin(b = 8)),
      plot.caption      = element_text(size = base_size - 2, colour = "#888888",
                                       hjust = 0, margin = margin(t = 8)),
      axis.title        = element_text(size = base_size - 1, colour = "#444444"),
      axis.text         = element_text(size = base_size - 2, colour = "#444444"),
      panel.grid.major  = element_line(colour = "#eeeeee", linewidth = 0.4),
      panel.grid.minor  = element_blank(),
      panel.background  = element_rect(fill = "white", colour = NA),
      plot.background   = element_rect(fill = "white", colour = NA),
      legend.position   = "bottom",
      legend.title      = element_blank(),
      legend.text       = element_text(size = base_size - 2)
    )
}

COL_OR    <- "#1a5276"
COL_FIT   <- "#c0392b"
COL_EP    <- "#117a65"
COL_SHADE <- "#d5e8f3"
COL_EPFIN <- "#a04000"

dir.create("figures", showWarnings = FALSE)
dir.create("outputs", showWarnings = FALSE)

# ================================================================
#  PARTIE A : DONNÉES MACRO US - Prix de l'or (1990-2020)
# ================================================================

# ----------------------------------------------------------------
# Source 1 : Taux directeur de la Fed (Federal Funds Rate, %)
#            Source : FRED/Federal Reserve, série FEDFUNDS
#            Disponible : https://fred.stlouisfed.org/series/FEDFUNDS
# ----------------------------------------------------------------
annees_or <- 1990:2020
```

```
fed_funds <- c(
  8.10, 5.69, 3.52, 3.02, 4.21, 5.84, 5.30, 5.46, 5.35, 5.00,  # 1990-1999
  6.24, 3.88, 1.67, 1.13, 1.35, 3.22, 5.02, 5.02, 1.92, 0.24,  # 2000-2009
  0.18, 0.10, 0.14, 0.11, 0.09, 0.13, 0.40, 1.00, 1.83, 2.16,  # 2010-2019
  0.36                                                             # 2020
)

# ----------------------------------------------------------------
# Source 2 : Inflation US (CPI, variation annuelle %)
#            Source : BLS/FRED, série CPIAUCSL
#            Disponible : https://fred.stlouisfed.org/series/CPIAUCSL
# ----------------------------------------------------------------
inflation_us <- c(
  5.40, 4.20, 3.01, 2.99, 2.61, 2.81, 2.95, 2.34, 1.55, 2.19,  # 1990-1999
  3.38, 2.83, 1.59, 2.27, 2.68, 3.39, 3.23, 2.85, 3.84, -0.36, # 2000-2009
  1.64, 3.16, 2.07, 1.46, 1.62, 0.12, 1.26, 2.13, 2.44, 1.81,  # 2010-2019
  1.23                                                             # 2020
)

# ----------------------------------------------------------------
# Source 3 : Prix du pétrole brut (WTI, USD/baril, moyenne annuelle)
#            Source : EIA/FRED, série DCOILWTICO
#            Disponible : https://fred.stlouisfed.org/series/DCOILWTICO
# ----------------------------------------------------------------
wti <- c(
  24.47, 21.54, 19.25, 16.97, 15.82, 16.75, 22.02, 18.64, 10.87, 16.56, # 1990-1999
  28.26, 23.00, 22.81, 28.10, 37.66, 50.04, 61.08, 72.34, 99.67, 53.56, # 2000-2009
  77.45, 94.88, 94.05, 97.98, 93.17, 48.66, 43.29, 50.80, 64.94, 57.03, # 2010-2019
  39.68                                                                    # 2020
)

# ----------------------------------------------------------------
# Source 4 : Taux de change EUR/USD (moyenne annuelle)
#            Source : BCE/FRED, série DEXUSEU (à partir de 1999)
#            Note : avant 1999, on utilise le cours ECU/USD (prédécesseur)
#            Source pré-1999 : Banque de France / BCE archives
# ----------------------------------------------------------------
eur_usd <- c(
  0.803, 0.762, 0.771, 0.838, 0.832, 0.844, 0.859, 0.882, 0.903, 0.940, # 1990-1999 (ECU/USD
approx)
  0.924, 0.896, 0.945, 1.131, 1.242, 1.245, 1.256, 1.370, 1.472, 1.395, # 2000-2009
  1.326, 1.393, 1.285, 1.328, 1.329, 1.110, 1.107, 1.130, 1.181, 1.120, # 2010-2019
  1.142                                                                    # 2020
)

# Assemblage du jeu de données or
# Lecture du prix de l'or depuis le fichier Excel
raw_or <- read_excel("ST_Or.xlsx", sheet = "valeurs_mensuelles", col_names = FALSE)
data_or <- raw_or[5:nrow(raw_or), 1:2]
colnames(data_or) <- c("date_str", "prix")
data_or$prix <- suppressWarnings(as.numeric(data_or$prix))
data_or <- data_or[!is.na(data_or$prix), ]
data_or$date <- as.Date(paste0(data_or$date_str, "-01"), format = "%Y-%m-%d")
data_or <- data_or[order(data_or$date), ]

# Agrégation en moyennes annuelles (1990-2020)
data_or_ann <- data_or %>%
  mutate(annee = as.integer(format(date, "%Y"))) %>%
  group_by(annee) %>%
  summarise(prix_moy = mean(prix, na.rm = TRUE), .groups = "drop") %>%
```

```
  filter(annee >= 1990, annee <= 2020)

# Fusion avec les variables macro
df_or <- data.frame(
  annee      = annees_or,
  log_or     = log(data_or_ann$prix_moy),
  fed_funds  = fed_funds,
  infl_us    = inflation_us,
  taux_reel  = fed_funds - inflation_us,  # taux d'intérêt réel US (approx.)
  log_wti    = log(wti),
  eur_usd    = eur_usd
)

cat("========================================\n")
cat("DONNEES OR + MACRO - Nb obs :", nrow(df_or), "\n")
cat("Période :", min(df_or$annee), "-", max(df_or$annee), "\n")
cat("========================================\n\n")

# ================================================================
#  MCO - PRIX DE L'OR
# ================================================================

cat("--- Modèles univariés (exploration) ---\n\n")

# Modèle 1 : taux directeur Fed seulement
ols_or_m1 <- lm(log_or ~ fed_funds, data = df_or)
cat("M1 - log(or) ~ taux_fed :\n"); print(summary(ols_or_m1))

# Modèle 2 : inflation US seulement
ols_or_m2 <- lm(log_or ~ infl_us, data = df_or)
cat("\nM2 - log(or) ~ inflation_us :\n"); print(summary(ols_or_m2))

# Modèle 3 : taux d'intérêt réel US
ols_or_m3 <- lm(log_or ~ taux_reel, data = df_or)
cat("\nM3 - log(or) ~ taux_reel_us :\n"); print(summary(ols_or_m3))

# Modèle 4 : prix du pétrole (WTI)
ols_or_m4 <- lm(log_or ~ log_wti, data = df_or)
cat("\nM4 - log(or) ~ log(WTI) :\n"); print(summary(ols_or_m4))

# Modèle 5 : taux de change EUR/USD
ols_or_m5 <- lm(log_or ~ eur_usd, data = df_or)
cat("\nM5 - log(or) ~ EUR/USD :\n"); print(summary(ols_or_m5))

cat("\n--- Modèles multivariés ---\n\n")

# Modèle 6 : taux réel + log(WTI)
ols_or_m6 <- lm(log_or ~ taux_reel + log_wti, data = df_or)
cat("M6 - log(or) ~ taux_reel + log(WTI) :\n"); print(summary(ols_or_m6))

# Modèle 7 : taux réel + log(WTI) + EUR/USD
ols_or_m7 <- lm(log_or ~ taux_reel + log_wti + eur_usd, data = df_or)
cat("\nM7 - log(or) ~ taux_reel + log(WTI) + EUR/USD :\n"); print(summary(ols_or_m7))

# Modèle 8 : modèle complet
ols_or_m8 <- lm(log_or ~ fed_funds + infl_us + log_wti + eur_usd, data = df_or)
cat("\nM8 - complet (fed + infl + WTI + EUR/USD) :\n"); print(summary(ols_or_m8))
```

```
# Tableau comparatif
tab_or <- data.frame(
  Modele = c("M1: taux_fed", "M2: infl_us", "M3: taux_reel",
             "M4: log(WTI)", "M5: EUR/USD",
             "M6: taux_reel + log(WTI)",
             "M7: M6 + EUR/USD",
             "M8: fed + infl + WTI + EUR/USD"),
  R2adj  = round(c(summary(ols_or_m1)$adj.r.squared, summary(ols_or_m2)$adj.r.squared,
                   summary(ols_or_m3)$adj.r.squared, summary(ols_or_m4)$adj.r.squared,
                   summary(ols_or_m5)$adj.r.squared, summary(ols_or_m6)$adj.r.squared,
                   summary(ols_or_m7)$adj.r.squared, summary(ols_or_m8)$adj.r.squared), 4),
  AIC    = round(c(AIC(ols_or_m1), AIC(ols_or_m2), AIC(ols_or_m3),
                   AIC(ols_or_m4), AIC(ols_or_m5), AIC(ols_or_m6),
                   AIC(ols_or_m7), AIC(ols_or_m8)), 2)
)
cat("\n--- Comparaison des modèles (or) ---\n")
print(tab_or)

# Tests diagnostiques - modèle retenu (M7)
bp_or7 <- bptest(ols_or_m7)
dw_or7 <- dwtest(ols_or_m7)
cat("\nBreusch-Pagan M7 :\n"); print(bp_or7)
cat("\nDurbin-Watson M7 :\n"); print(dw_or7)

# Matrice de corrélation des variables explicatives
mat_cor_or <- cor(df_or[, c("log_or", "taux_reel", "log_wti", "eur_usd", "fed_funds",
"infl_us")])
cat("\nMatrice de corrélation :\n")
print(round(mat_cor_or, 3))

sink("outputs/mco_or.txt")
cat("MCO - PRIX DE L'OR (1990-2020)\n\n")
cat("Sources : FRED/BLS (taux Fed, CPI US), EIA (WTI), BCE (EUR/USD)\n\n")
for (i in 1:8) {
  m <- list(ols_or_m1, ols_or_m2, ols_or_m3, ols_or_m4,
            ols_or_m5, ols_or_m6, ols_or_m7, ols_or_m8)[[i]]
  cat(sprintf("Modele M%d :\n", i)); print(summary(m)); cat("\n")
}
cat("Comparaison modeles :\n"); print(tab_or)
cat("\nBreusch-Pagan M7 :\n"); print(bp_or7)
cat("\nDurbin-Watson M7 :\n"); print(dw_or7)
cat("\nMatrice de correlation :\n"); print(round(mat_cor_or, 3))
sink()



# ================================================================
#  GRAPHIQUES MCO - OR
# ================================================================

# Figure A - Scatter plots variables vs log(or)
p_or_a <- ggplot(df_or, aes(x = taux_reel, y = log_or)) +
  geom_point(colour = COL_OR, size = 2.2) +
  geom_smooth(method = "lm", se = TRUE, colour = COL_FIT,
              fill = COL_SHADE, alpha = 0.3) +
  labs(title = "Taux reel US vs log(or)",
       x = "Taux reel US (%)", y = "Log(prix or)") +
  theme_insee()
```

```
p_or_b <- ggplot(df_or, aes(x = log_wti, y = log_or)) +
  geom_point(colour = COL_OR, size = 2.2) +
  geom_smooth(method = "lm", se = TRUE, colour = COL_FIT,
              fill = COL_SHADE, alpha = 0.3) +
  labs(title = "Log(WTI) vs log(or)",
       x = "Log(prix WTI, USD/baril)", y = "Log(prix or)") +
  theme_insee()

p_or_c <- ggplot(df_or, aes(x = eur_usd, y = log_or)) +
  geom_point(colour = COL_OR, size = 2.2) +
  geom_smooth(method = "lm", se = TRUE, colour = COL_FIT,
              fill = COL_SHADE, alpha = 0.3) +
  labs(title = "EUR/USD vs log(or)",
       x = "Taux de change EUR/USD", y = "Log(prix or)") +
  theme_insee()

p_or_d <- ggplot(df_or, aes(x = infl_us, y = log_or)) +
  geom_point(colour = COL_OR, size = 2.2) +
  geom_smooth(method = "lm", se = TRUE, colour = COL_FIT,
              fill = COL_SHADE, alpha = 0.3) +
  labs(title = "Inflation US vs log(or)",
       x = "Inflation US (%, CPI)", y = "Log(prix or)") +
  theme_insee()

fig_scatteror <- grid.arrange(p_or_a, p_or_b, p_or_c, p_or_d, ncol = 2,
  top = grid::textGrob(
    "Relations entre le prix de l'or et les variables macro (1990-2020)",
    gp = grid::gpar(fontsize = 12, fontface = "bold", col = "#2c3e50")))
ggsave("figures/fig_scatter_or.png", fig_scatteror,
       width = 24, height = 16, units = "cm", dpi = 150, bg = "white")
cat("Figure scatter or sauvegardee.\n")

# Figure B - Ajustement + résidus modèle retenu (M7)
df_or$fitted_m7 <- fitted(ols_or_m7)
df_or$res_m7    <- residuals(ols_or_m7)

p_fit_or <- ggplot(df_or, aes(x = annee)) +
  geom_line(aes(y = log_or,     colour = "Observe"),  linewidth = 0.9) +
  geom_line(aes(y = fitted_m7,  colour = "Ajuste"),   linewidth = 0.85, linetype = "dashed") +
  scale_colour_manual(values = c("Observe" = COL_OR, "Ajuste" = COL_FIT)) +
  scale_x_continuous(breaks = seq(1990, 2020, by = 5)) +
  labs(title = "Ajustement MCO M7 : log(or) observe vs ajuste",
       x = "Annee", y = "Log(prix or, USD/once)") +
  theme_insee()

p_res_or <- ggplot(df_or, aes(x = annee, y = res_m7)) +
  geom_hline(yintercept = 0, colour = "#aaaaaa", linewidth = 0.5) +
  geom_line(colour = COL_OR, linewidth = 0.7) +
  geom_point(colour = COL_OR, size = 1.8) +
  scale_x_continuous(breaks = seq(1990, 2020, by = 5)) +
  labs(title = "Residus MCO M7",
       x = "Annee", y = "Residus") +
  theme_insee()

fig_fit_or <- grid.arrange(p_fit_or, p_res_or, ncol = 2,
  top = grid::textGrob(
    "MCO M7 - log(or) ~ taux_reel + log(WTI) + EUR/USD (1990-2020)",
    gp = grid::gpar(fontsize = 12, fontface = "bold", col = "#2c3e50")))
ggsave("figures/fig_mco_or.png", fig_fit_or,
```

```
       width = 24, height = 13, units = "cm", dpi = 150, bg = "white")
cat("Figure MCO or (ajustement+residus) sauvegardee.\n")


# ================================================================
#  PARTIE B : DONNEES MACRO FRANCE - Taux d'épargne (1970-2018)
# ================================================================

# Lecture du taux d'épargne depuis Excel
raw_ep <- read_excel("Epargne_Menage.xlsx", sheet = "Figure 4", col_names = FALSE)
data_ep <- as.data.frame(raw_ep[5:73, 1:4])
colnames(data_ep) <- c("annee", "tx_brut", "tx_invest", "tx_fin")
data_ep[] <- lapply(data_ep, as.numeric)
data_ep   <- data_ep[!is.na(data_ep$annee), ]

# Restriction à 1970-2018 (où les données macro sont disponibles)
data_ep70 <- data_ep[data_ep$annee >= 1970, ]

annees_ep <- 1970:2018

# ----------------------------------------------------------------
# Source 5 : Taux d'inflation France (CPI, variation annuelle %)
#            Source : INSEE (séries longues de l'IPC France)
#            Référence : INSEE, séries longues sur les indices de prix à la consommation
#            URL : https://www.insee.fr/fr/statistiques/2417384
# ----------------------------------------------------------------
inflation_fr <- c(
  5.24, 5.53, 5.87, 7.33, 13.67, 11.75, 9.62, 9.44, 9.09, 10.76, # 1970-1979
  13.63, 13.39, 11.96, 9.58,  7.44,  5.82,  2.70,  3.12, 2.71, 3.52, # 1980-1989
  3.37,  3.21,  2.37, 2.10,  1.68,  1.79,  1.97,  1.19, 0.74, 0.57,  # 1990-1999
  1.83,  1.78,  1.94, 2.17,  2.33,  1.90,  1.92,  1.61, 3.16, 0.09,  # 2000-2009
  1.74,  2.29,  2.17, 1.01,  0.62,  0.11,  0.33,  1.17, 2.11         # 2010-2018
)

# ----------------------------------------------------------------
# Source 6 : Taux de croissance du PIB réel France (%)
#            Source : INSEE (comptes nationaux, base 2014)
#            Référence : INSEE, séries longues comptes nationaux
#            URL : https://www.insee.fr/fr/statistiques/2832942
# ----------------------------------------------------------------
croissance_pib <- c(
  5.70, 4.80, 5.90, 5.40,  3.18, -0.93, 4.21, 3.12, 3.37, 3.23, # 1970-1979
  1.62, 1.05, 2.34, 1.34,  1.45,  1.99, 2.42, 2.31, 4.55, 4.40, # 1980-1989
  2.89, 1.05, 1.52,-0.61,  2.24,  2.11, 1.39, 2.25, 3.61, 3.39, # 1990-1999
  3.94, 2.00, 1.10, 0.83,  2.83,  1.74, 2.41, 2.35, 0.24,-2.87, # 2000-2009
  1.94, 2.19, 0.34, 0.62,  0.93,  1.07, 1.19, 2.29, 1.76        # 2010-2018
)

# ----------------------------------------------------------------
# Source 7 : Taux de chômage France (BIT, %)
#            Source : INSEE, enquête Emploi / comptes de l'emploi
#            URL : https://www.insee.fr/fr/statistiques/serie/001688526
# ----------------------------------------------------------------
taux_chomage <- c(
  2.50, 2.70, 2.80, 2.70, 2.80, 3.79, 4.42, 4.82, 5.28, 5.94, # 1970-1979
  6.16, 7.36, 8.07, 8.36, 9.74,10.25,10.54,10.68,10.18, 9.54, # 1980-1989
  8.87, 9.43,10.41,11.66,12.30,11.68,12.34,12.26,11.72,10.82, # 1990-1999
  9.27, 8.55, 8.89, 9.50, 9.92, 9.28, 9.25, 7.97, 7.79, 9.49, # 2000-2009
  9.73, 9.61,10.19,10.30,10.32,10.44,10.10, 9.38, 9.01        # 2010-2018
```

```
)

# ----------------------------------------------------------------
# Source 8 : Taux d'intérêt à long terme France (OAT 10 ans, %)
#            Source : Banque de France / BCE / OCDE
#            URL : https://www.banque-france.fr/statistiques/taux-et-cours
# ----------------------------------------------------------------
taux_lt <- c(
  8.49, 8.35, 8.36, 9.22,11.51,10.34,10.50,11.01,10.64,10.43, # 1970-1979
  13.73,15.68,15.68,14.38,13.35,11.94, 8.74, 9.47, 9.01, 8.77, # 1980-1989
  9.92, 9.04, 8.57, 6.87, 7.24, 7.53, 6.30, 5.58, 4.65, 4.61, # 1990-1999
  5.39, 5.03, 4.86, 4.15, 4.12, 3.42, 3.80, 4.30, 4.23, 3.65, # 2000-2009
  3.12, 3.32, 2.54, 2.20, 1.67, 0.84, 0.47, 0.82, 0.78        # 2010-2018
)

# Assemblage du jeu de données épargne
df_ep <- data.frame(
  annee      = annees_ep,
  tx_brut    = data_ep70$tx_brut,
  infl_fr    = inflation_fr,
  pib_croiss = croissance_pib,
  chomage    = taux_chomage,
  taux_lt    = taux_lt
)

cat("\n========================================\n")
cat("DONNEES EPARGNE + MACRO - Nb obs :", nrow(df_ep), "\n")
cat("Période : 1970-2018\n")
cat("========================================\n\n")

# ================================================================
#  MCO - TAUX D'ÉPARGNE
# ================================================================

cat("--- Modèles univariés (exploration) ---\n\n")

# Modèle 1 : inflation seule
ols_ep_m1 <- lm(tx_brut ~ infl_fr, data = df_ep)
cat("M1 - tx_brut ~ inflation_fr :\n"); print(summary(ols_ep_m1))

# Modèle 2 : croissance PIB
ols_ep_m2 <- lm(tx_brut ~ pib_croiss, data = df_ep)
cat("\nM2 - tx_brut ~ croissance_pib :\n"); print(summary(ols_ep_m2))

# Modèle 3 : taux de chômage
ols_ep_m3 <- lm(tx_brut ~ chomage, data = df_ep)
cat("\nM3 - tx_brut ~ taux_chomage :\n"); print(summary(ols_ep_m3))

# Modèle 4 : taux d'intérêt long terme
ols_ep_m4 <- lm(tx_brut ~ taux_lt, data = df_ep)
cat("\nM4 - tx_brut ~ taux_lt :\n"); print(summary(ols_ep_m4))

cat("\n--- Modèles multivariés ---\n\n")

# Modèle 5 : inflation + taux LT
ols_ep_m5 <- lm(tx_brut ~ infl_fr + taux_lt, data = df_ep)
cat("M5 - tx_brut ~ infl + taux_lt :\n"); print(summary(ols_ep_m5))
```

```
# Modèle 6 : taux LT + chômage
ols_ep_m6 <- lm(tx_brut ~ taux_lt + chomage, data = df_ep)
cat("\nM6 - tx_brut ~ taux_lt + chomage :\n"); print(summary(ols_ep_m6))

# Modèle 7 : taux LT + chômage + PIB
ols_ep_m7 <- lm(tx_brut ~ taux_lt + chomage + pib_croiss, data = df_ep)
cat("\nM7 - tx_brut ~ taux_lt + chomage + pib :\n"); print(summary(ols_ep_m7))

# Modèle 8 : modèle complet
ols_ep_m8 <- lm(tx_brut ~ infl_fr + pib_croiss + chomage + taux_lt, data = df_ep)
cat("\nM8 - complet :\n"); print(summary(ols_ep_m8))

# Tableau comparatif
tab_ep <- data.frame(
  Modele = c("M1: inflation_fr", "M2: croissance_pib", "M3: chomage",
             "M4: taux_lt", "M5: infl + taux_lt",
             "M6: taux_lt + chomage",
             "M7: taux_lt + chomage + pib",
             "M8: complet"),
  R2adj  = round(c(summary(ols_ep_m1)$adj.r.squared, summary(ols_ep_m2)$adj.r.squared,
                   summary(ols_ep_m3)$adj.r.squared, summary(ols_ep_m4)$adj.r.squared,
                   summary(ols_ep_m5)$adj.r.squared, summary(ols_ep_m6)$adj.r.squared,
                   summary(ols_ep_m7)$adj.r.squared, summary(ols_ep_m8)$adj.r.squared), 4),
  AIC    = round(c(AIC(ols_ep_m1), AIC(ols_ep_m2), AIC(ols_ep_m3),
                   AIC(ols_ep_m4), AIC(ols_ep_m5), AIC(ols_ep_m6),
                   AIC(ols_ep_m7), AIC(ols_ep_m8)), 2)
)
cat("\n--- Comparaison des modèles (epargne) ---\n")
print(tab_ep)

# Tests diagnostiques - modèle retenu
best_ep <- which.min(tab_ep$AIC)
cat("\nModele retenu : M", best_ep, "(AIC minimal)\n")
mlist_ep <- list(ols_ep_m1, ols_ep_m2, ols_ep_m3, ols_ep_m4,
                 ols_ep_m5, ols_ep_m6, ols_ep_m7, ols_ep_m8)
best_ep_model <- mlist_ep[[best_ep]]
cat("\nSummary modele retenu :\n"); print(summary(best_ep_model))
bp_ep_best <- bptest(best_ep_model)
dw_ep_best <- dwtest(best_ep_model)
cat("\nBreusch-Pagan modele retenu :\n"); print(bp_ep_best)
cat("\nDurbin-Watson modele retenu :\n"); print(dw_ep_best)

mat_cor_ep <- cor(df_ep[, c("tx_brut", "infl_fr", "pib_croiss", "chomage", "taux_lt")])
cat("\nMatrice de correlation :\n"); print(round(mat_cor_ep, 3))

sink("outputs/mco_ep.txt")
cat("MCO - TAUX D'EPARGNE (1970-2018)\n\n")
cat("Sources : INSEE (inflation, PIB, chomage), Banque de France (taux LT)\n\n")
for (i in 1:8) {
  cat(sprintf("Modele M%d :\n", i))
  print(summary(mlist_ep[[i]])); cat("\n")
}
cat("Comparaison modeles :\n"); print(tab_ep)
cat("\nBreusch-Pagan modele retenu :\n"); print(bp_ep_best)
cat("\nDurbin-Watson modele retenu :\n"); print(dw_ep_best)
cat("\nMatrice de correlation :\n"); print(round(mat_cor_ep, 3))
sink()
```

```
# ================================================================
#  GRAPHIQUES MCO - ÉPARGNE
# ================================================================

# Figure C - Scatter plots
p_ep_a <- ggplot(df_ep, aes(x = taux_lt, y = tx_brut)) +
  geom_point(colour = COL_EP, size = 2.0) +
  geom_smooth(method = "lm", se = TRUE, colour = COL_FIT,
              fill = "#c8e6c9", alpha = 0.3) +
  scale_y_continuous(labels = label_number(suffix = " %")) +
  labs(title = "Taux LT vs epargne",
       x = "OAT 10 ans (%)", y = "Taux d'epargne (%)") +
  theme_insee()

p_ep_b <- ggplot(df_ep, aes(x = chomage, y = tx_brut)) +
  geom_point(colour = COL_EP, size = 2.0) +
  geom_smooth(method = "lm", se = TRUE, colour = COL_FIT,
              fill = "#c8e6c9", alpha = 0.3) +
  scale_y_continuous(labels = label_number(suffix = " %")) +
  labs(title = "Chomage vs epargne",
       x = "Taux de chomage (%)", y = "Taux d'epargne (%)") +
  theme_insee()

p_ep_c <- ggplot(df_ep, aes(x = infl_fr, y = tx_brut)) +
  geom_point(colour = COL_EP, size = 2.0) +
  geom_smooth(method = "lm", se = TRUE, colour = COL_FIT,
              fill = "#c8e6c9", alpha = 0.3) +
  scale_y_continuous(labels = label_number(suffix = " %")) +
  labs(title = "Inflation vs epargne",
       x = "Inflation France (%)", y = "Taux d'epargne (%)") +
  theme_insee()

p_ep_d <- ggplot(df_ep, aes(x = pib_croiss, y = tx_brut)) +
  geom_point(colour = COL_EP, size = 2.0) +
  geom_smooth(method = "lm", se = TRUE, colour = COL_FIT,
              fill = "#c8e6c9", alpha = 0.3) +
  scale_y_continuous(labels = label_number(suffix = " %")) +
  labs(title = "Croissance PIB vs epargne",
       x = "Croissance PIB reel (%)", y = "Taux d'epargne (%)") +
  theme_insee()

fig_scatterep <- grid.arrange(p_ep_a, p_ep_b, p_ep_c, p_ep_d, ncol = 2,
  top = grid::textGrob(
    "Relations entre le taux d'epargne et les variables macro (1970-2018)",
    gp = grid::gpar(fontsize = 12, fontface = "bold", col = "#2c3e50")))
ggsave("figures/fig_scatter_ep.png", fig_scatterep,
       width = 24, height = 16, units = "cm", dpi = 150, bg = "white")
cat("Figure scatter epargne sauvegardee.\n")

# Figure D - Ajustement + résidus modèle retenu épargne
df_ep$fitted_best <- fitted(best_ep_model)
df_ep$res_best    <- residuals(best_ep_model)

p_fit_ep <- ggplot(df_ep, aes(x = annee)) +
  geom_line(aes(y = tx_brut,      colour = "Observe"),  linewidth = 0.9) +
  geom_line(aes(y = fitted_best,  colour = "Ajuste"),   linewidth = 0.85, linetype = "dashed") +
  scale_colour_manual(values = c("Observe" = COL_EP, "Ajuste" = COL_FIT)) +
  scale_x_continuous(breaks = seq(1970, 2018, by = 10)) +
  scale_y_continuous(labels = label_number(suffix = " %")) +
```

```
  labs(title = "Ajustement MCO : epargne observee vs ajustee",
       x = "Annee", y = "Taux d'epargne brut (%)") +
  theme_insee()

p_res_ep <- ggplot(df_ep, aes(x = annee, y = res_best)) +
  geom_hline(yintercept = 0, colour = "#aaaaaa", linewidth = 0.5) +
  geom_line(colour = COL_EP, linewidth = 0.7) +
  geom_point(colour = COL_EP, size = 1.5) +
  scale_x_continuous(breaks = seq(1970, 2018, by = 10)) +
  labs(title = "Residus MCO (epargne)", x = "Annee", y = "Residus (pp)") +
  theme_insee()

fig_fit_ep <- grid.arrange(p_fit_ep, p_res_ep, ncol = 2,
  top = grid::textGrob(
    paste0("MCO - taux d'epargne ~ modele retenu (1970-2018)"),
    gp = grid::gpar(fontsize = 12, fontface = "bold", col = "#2c3e50")))
ggsave("figures/fig_mco_ep.png", fig_fit_ep,
       width = 24, height = 13, units = "cm", dpi = 150, bg = "white")
cat("Figure MCO epargne (ajustement+residus) sauvegardee.\n")

cat("\n=== SCRIPT MCO TERMINE ===\n")
cat("Figures sauvegardees : fig_scatter_or.png, fig_mco_or.png\n")
cat("                       fig_scatter_ep.png, fig_mco_ep.png\n")
cat("Outputs : outputs/mco_or.txt, outputs/mco_ep.txt\n")
```